Ejercicios Tema 2

Buffer de sólo 2 marcos, ocurre la siguiente secuencia de operaciones:

- Usuario lee página A
- Usuario lee página B
- Usuario modifica página A
- Usuario lee página C

La secuencia es la siguiente:

1. Cargamos la página 1 en el 1er marco
2. Cargamos la página 2 en el 2nd marco
3. Modificamos página A, por tanto es el último al que hemos accedido
4. Borramos B, ya que es el que más tiempo llevamos sin usar y como no lo hemos modificado no lo tenemos que escribir en el disco. Sustituimos B por C

Borrar Gómez:

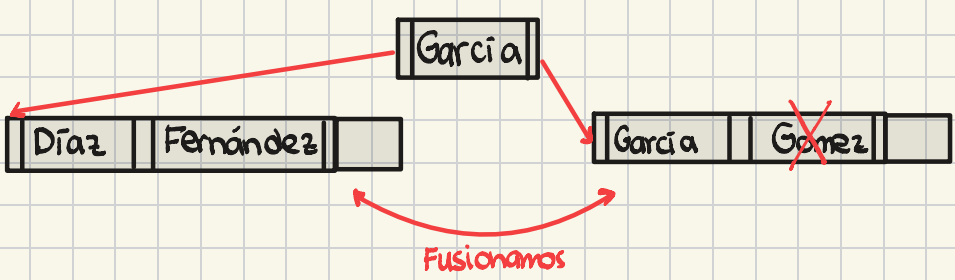

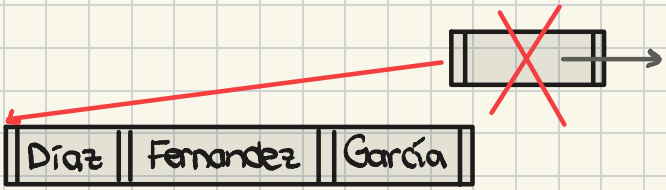

Al no haber rama derecha no necesitamos la clave. Además si esta se queda vacía reducimos un nivel de altura en el árbol

1. Context i Esquema de la Base de Dades

Es disposa d'un sistema relacional per al catàleg de patrimoni artístic estructurat en tres taules:

- **Artistas** (id, nombre, año_nacimiento, pais_nacimiento)
- **Museos** (id, nombre, pais_museo)
- **Obras** (id, nombre_obra, año_creacion, id_autor, id_museo_expuesta)

Restriccions d'Integritat Referencial:

- Obras.id_autor és clau aliena que referència a Artistas.id (no admet nuls).
- Obras.id_museo_expuesta és clau aliena que fa referència a Museos.id (no admet nuls).

2. Paràmetres tècnics i estructura d'índexs

Paràmetre / Estructura	Valor / Configuració	Descripció Tècnica
Organització física de fitzers	Seqüencial no ordenat (Heap)	Inserció al final, sense ordenament físic de tuples.
Indexs d'agrupament (Clustered B^+)	Clau Primaria (id)	Definits sobre la PK de Artistas, Museos y Obras.
Indezs de no agrupament (Unclustered B^+)	Obras.id_autor Obras.año_creacion	Indexs secundaris sobre les Claus alienes i atributs de cerca freqüent.
Alçada d'indexs B^+ (h)	3 blocs (h = 3)	Nombre d'accessos a disc per recòrrer des de l'arrel a la fulla.
Mida de blocs de disc (L_B)	2.000 bytes	Capacitat útil per bloc físic d'enmagatzenatge
Memòria intermèdia (B)	20 blocs	Buffer pool disponible en memòria principal.

3. Especificacions de Camps i Estadístiques del Catàleg

Taula	Camps y Longituds (Bytes)	Nombre Tuplas (N_r)	Valors Diferents V(A, r)
Artistas	id (10), nombre (100), año_nacimiento (10), pais_nacimiento (60)	80	V(pais_nacimiento, Artistas) = 20
Museos	id (10), nombre (100), pais_museo (60)	40	V(pais_museo, Museos) = 15
Obras	id (10), nombre_obra (100), año_creacion (10), id_autor (10), id_museo_expuesta (10)	2.000	V(año_creacion, Obras) = 100 V(id_autor, Obras) = 80

Qüestió 1: Calcular la mida en bytes de cada registre (LR), el factor de bloqueig (f que ocupa cadascuna de les tres taules al sistema.

Artistas:

LR = id(10) + nombre(100) + año_nacimiento(10) + pais_nacimiento(60) = 180 bytes

FB = TB / LR = 2000 / 180 = 11,11 → 11 registros

Museos:

LR = id(10) + nombre(100) + pais_museo(60) = 170

FB = 2000 / 170 = 11,74 → 11 registros

Obras:

LR = id(10) + nombre_obra(100) + año_creacion(10) + id_autor(10) + id_museo_expuesta(10) = 140

FB = 2000 / 140 = 14,28 → 14 registros

Qüestió 2: Quants blocs de disc caldria llegir per trobar i mostrar totes les dades d'una obra atesa la clau primària id?

Buscaríamos en el árbol (h) donde: h = 3. Por tanto el número de bloques que tendríamos que leer es de: h+1 → 3+1 = 4 bloques

Qüestió 3: Quants blocs de disc cal llegir per llistar l'id i nom_obra de totes les obres creades per un artista específic donat el seu id_autor?

Tenemos un índice de no agrupamiento en obras.id_autor, como la tabla obras tiene 2000 tuplas y hay 80 autores diferentes con una distribución uniforme suponemos que cada autor ha hecho 25 cuadros (2000 / 80 = 25)

como el indice es de no agrupamiento las obras en el peor de los casos estarán distribuidas y el sistema tendria que dar 25 saltos.

Coste = 3 (arbol) + 25 (peor caso) = 28 bloques

Qüestió 4: Quants blocs de disc caldria escriure per desar en disc el resultat de la consulta plantejada a la Qüestió 3?

Calculamos el coste en bytes de los 25 registros

LR = id(10) + nombre_obra (100) = 110 bytes → 25 * 110 = 2750 bytes

Como el TB = 2000 necesitaremos escribir : 2750/2000 = 1,37

↳ 2 bloques

Qüestió 5: Quants blocs cal llegir per trobar el nom_obra i l'id_autor de totes les obres creades en un any determinat (per exemple, l'any 1925)?

Suponiendo que en cada año se hayan hecho el mismo num de cuadros entonces: 2000/100 = 20 cuadros/año

Mismo caso que anterior (indice de no agrupamiento):

Coste = 3 (arbol) + 20 (peor caso) = 23 bloques

Qüestió 6: Quants blocs de disc caldria escriure per desar en disc el resultat de la consulta plantejada a la Qüestió 5?

Calculamos el coste en bytes de los 20 registros

LR = id(10) + nombre_obra (100) = 110 bytes → 20 * 110 = 2200 bytes

Como el TB = 2000 necesitaremos escribir : 2200/2000 = 1,1

↳ 2 bloques

Qüestió 7: Quants blocs de disc caldria llegir per llistar l'id i el nom de tots els artistes nascuts en un determinat pais_naixement? Justificar quantitativament si seria rendible afegir un índex sobre aquest camp.

Como no tenemos ningún índice el peor coste para encontrar el país de nacimiento sería recorrer todos los bloques de la tabla

Sabemos que: FB = 11 registros → 80 tuplas / 11 registros = 7,27 → 8 bloq

Con esos 8 bloques podemos resolver la consulta.

Si creamos un índice (no agrupamiento):

Suponiendo que hay el mismo número de artistas por país (80/20 = 4)

Coste = 3 (arbol) + 4 (por caso) = 7 bloques.

Concluimos que con un índice leemos un menor número de bloques

Qüestió 8: Quants blocs de disc cal llegir per llistar l'id i el nom de tots els museus ubicats en un país determinat? I quants blocs per guardar aquest resultat al disc?

Igual que la cuestión anterior:

40/11 = 3,63 → 4 bloques

Para saber cuantos bloques necesitamos para escribir necesitamos el tamaño en bytes de todos los registros que queremos guardar → 3 * 110 = 330 bytes

Observamos que cabe sobradamente en un único bloque

En la estación de autobuses de Valencia se tiene una BD con el siguiente esquema:

`Autobus(`**`numBus`**`, marca, numEmpresa)`

`Empresa(`**`numEmpresa`**`, nombreEmpresa, fechaCreacion, direccion)`

`Viaje(`**`numBus, fechaViaje`**`, destino)`

- Autobus.numEmpresa no admite nulos y es clave ajena de Empresa
- Viaje.numBus es clave ajena de Autobus

Se sabe que:

- La organización de todos los ficheros es secuencial no ordenada
- Existen índices de agrupamiento tipo B+ sobre todas las claves primarias de las tablas
- Se tiene un índice B+ de no agrupamiento sobre Viaje.destino
- La altura en bloques de todos los árboles de índices es 3
- La longitud de los campos es de 10 bytes cada uno

Se conoce la siguiente información estadística:

- Tuplas Autobus: 10.000
- Tuplas Empresa: 1.000
- Tuplas Viaje: 250.000
- Valores de destino distintos: 200. Valores de marca distintos: 10

Además

- El sistema cuenta con 20 bloques de memoria (B=20)
- El tamaño de bloque es 2000 bytes (LB=2000)
- Se asume distribución uniforme, cuando los datos no sean datos explícitamente.

1. ¿Cuántos bloques tiene cada una de las tablas?

Autobus:

FB = TB / LR = 2000 / 30 = 66 registros / bloque

BT = Tuplas / Registros = 10000 / 66 = 152 bloques

Empresa:

FB = 2000 / 40 = 50 registros / bloque

BT = 1000 / 50 = 20 bloques

Viaje:

FB = 2000 / 30 = 66 registros / bloque

BT = 250.000 / 66 = 3787,87 → 3788 bloques

2. ¿Cuántos bloques habría que leer para encontrar y mostrar todos los datos de un autobús dado su numBus?

Coste = 3 (arbol) + 1 (leer dato) = 4

3. ¿Cuántos bloques habría que leer para listar el numBus de todos los autobuses de una empresa dado el código numEmpresa de la misma?

Como no tenemos índice tenemos que recorrer todos los bloques de la tabla, por tanto tenemos que leer 152 bloques

4. ¿Cuántos bloques habría que escribir para guardar en disco el resultado anterior?

Sabemos que hay 10000 autobuses y 1000 empresas, aplicando la distribución uniforme: 10000/1000 = 10 autobuses/empresa
Como solo queremos guardar numBus: $|R_1| = 10 * 10 = 100$ bytes
Por tanto esos bytes caben en un sólo bloque.

5. ¿Cuántos bloques habría que leer para encontrar el numBus y fechaViaje de todos los viajes con destino Madrid?

Calculamos el numero de viajes a madrid: 250000/200 = 1250
Coste = 3 (arbol) + 1250 (peor caso) = 1253 bloques

6. ¿Cuántos bloques habría que escribir para guardar en disco el resultado anterior?

Calculamos los bytes de los registros que queremos escribir: 20 * 1250 = 25000 bytes
Calculamos los bloques que necesitamos:
25000 / 2000 = 12,5 → 13 bloques

7. ¿Cuántos bloques habría que leer para listar el numBus de todos los autobuses de una empresa dado el código numEmpresa de la misma, si la tabla Autobus tuviera un índice sobre numEmpresa? ¿De qué tipo sería ese índice?

Ya sabemos que hay 10 autobuses por empresa, por tanto:

Coste = 3 (arbol) + 10 (peor coste) = 13 bloques

Estaríamos hablando de un índice de no agrupamiento ya que ya tenemos un índice de agrupamiento sobre la PK

8. ¿Cuántos bloques habría que leer para listar el numBus y el numEmpresa de todos los autobuses de una marca dada? ¿Cuántos bloques habría que escribir para guardar en disco el resultado? ¿Sería mejor si tuviéramos un índice sobre el campo marca en la tabla Autobus?

Lectura:

Tendríamos que leer los 152 bloques porque no tenemos índice

Escritura:

Calculamos el numero de Autobuses de una marca en concreto: 10000/10 = 1000

Calculamos el número de bytes de la información:

20 * 1000 = 20000 bytes

Calculamos el número de bloques que necesitamos:

20000/2000 = 10 bloques

Si tuvieramos un índice (tendria que ser no agrupamiento) tendriamos que leer más bloques → 3 (arbol) + 1000 (pc) = 1003 bloques

Ejercicios Tema 3

En la estación de autobuses de Valencia se tiene un sistema con el siguiente esquema de base de datos:

Autobus(**numBus**, matricula, marca, numEmpresa)

Empresa(**numEmpresa**, nombreEmpresa, email, dirección, telefono)

Viaje(**numBus**, **fechaViaje**, destino)

- Autobus.numEmpresa no admite nulos y es clave ajena de Empresa
- Viaje.numBus es clave ajena de Autobus

Se desea optimizar la siguiente consulta:

```
select matricula, fechaViaje
from Autobus join Viaje on Autobus.numbus = Viaje.numBus
  join Empresa on Autobus.numEmpresa=Empresa.numEmpresa
where destino = 'Madrid' and nombreEmpresa='Alsa'
```

Se cuenta con las siguientes estructuras adicionales:

- Existen índices de agrupamiento tipo B+ sobre todas las claves primarias de las tablas
- Hay índices B+ de no agrupamiento sobre Viaje.destino y sobre Autobus.numEmpresa
- La altura en bloques de todos los árboles de índices es 3
- La longitud de los campos es de 10 bytes cada uno, y el FB de los índices es 100

Se conoce la siguiente información estadística:

- Tuplas Autobus: 100.000
- Tuplas Empresa: 10.000
- Tuplas Viaje: 250.000
- El número de **destinos** distintos es 200.

Además

- El sistema cuenta con 20 bloques de memoria (B=20)
- El tamaño de bloque es 2000 bytes (LB=2000)
- Se asume distribución uniforme, cuando los datos no sean datos explícitamente.

Dibuja el árbol algebraico de la consulta y obtén el árbol optimizado, e indica cuál sería el plan físico de ejecución.

¿Sería recomendable crear algún índice adicional para mejorar la ejecución de esta consulta?

¿Cómo se modificaría el resultado si supiéramos que el 10% de los viajes van a Madrid?

Árbol genérico:

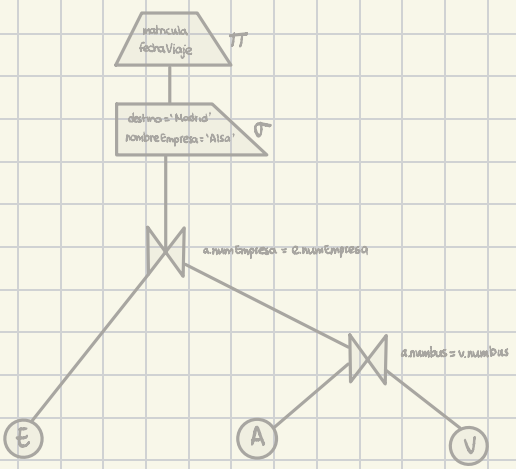

Árbol optimizado:

Importante: para construir la tabla optimizada leer consulta de abajo a arriba (incluido joins)

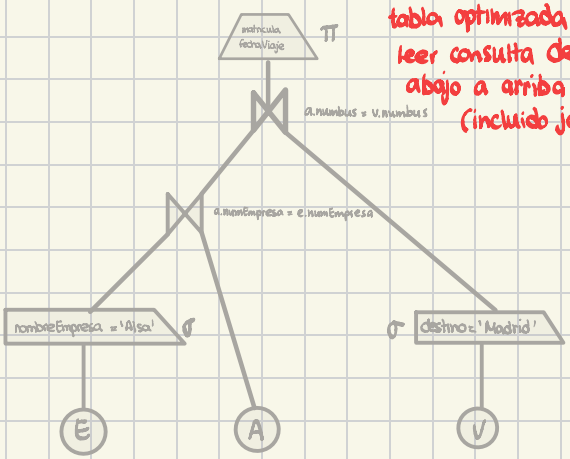

Plan físico de ejecución

Calculamos el factor de selectividad de Viajes

$S_i = 1/200 = 0{,}005$

Una vez calculado necesitamos saber cuantas tuplas sobreviven a este filtro:

Tuplas = 250.000 * 0,005 = 1250 tuplas

A continuación calculamos el numero de bloques de leer la tabla completa usar el índice de no agrupamiento.

Calculamos el nº de bloques que ocupa la tabla:

$FB = TB / LR = 2000/30 = 66,\widehat{66} \rightarrow 66$ registros

B_T = Tuplas / registros = 250.000/66 = 3787,8 → 3788 bloques

1. Leer toda la tabla:

Recorremos los 3732 bloques

2. Aplicar índice no agrupamiento:

Como ya conocemos que hay 1250 viajes a Madrid el coste será:

Coste = 3 (árbol) + 1250/100 + 1250 (peor caso) = 1265,5 → 1266 bloques

Por tanto el SGBD elegirá la opción del índice

Calculamos el factor de selectividad de Empresas:

$S_2 = 1/10000 = 0,0001$

Aplicamos el filtro para ver cuantas tuplas sobreviven:

Tuplas = 10000 * 0,0001 = 1

Calculamos el nº de bloques que ocupa la tabla:

$FB = 2000/50 = 40$ registros

$B_T = 10000/40 = 250$ bloques

1. Leemos toda la tabla

Recorremos los 250 bloques

Una vez esto calculamos la reunión entre autobuses y empresas:

Como Autobuses está intacta calculamos el coste de leer los bloques aplicando el índice de no agrupamiento y filtando por el ID de la empresa 'Alsa'.

Autobuse Alsa = 100000 / 1000 = 10 tuplas

Coste = 3 (árbol) + 10/100 + 10 + 1 = 14,1 → 15 bloques

Por último calculamos la última reunión:

Como nos quedan tablas temporales sin índices el SGBD aplica el algoritmo BNLJ (bucle exterior el menos costoso)

Calculamos los bloques de estas tablas temporales:

Autobus: FB = 2000 / 40 = 50 registros

B_T = 10 / 50 = 0,2 → 1 bloque

Viaje: B_T = 1250 / 66 = 18,9 → 19 bloques

Como la tabla temporal de autobus es mas pequeña actuará como bucle exterior, por tanto el coste del cruce es:

Coste = 1 (temporal autobus) + 19 (temporal viaje) = 20 bloques

* Si supieramos que el 10% de los viajes van a madrid el coste sería:

Coste = 3 (árbol) + 25000 / 100 + 25000 = 25253 bloques

Siendo mejor leer toda la tabla

PASO A PASO EJERCICIOS:

Fase 1: Filtrado inicial y accesos base (Selecciones σ)

- Calcula las tuplas supervivientes usando el factor de selectividad: $S = 1 / valores_distintos$. Multiplica S por el total de tuplas originales.
- Evalúa el escaneo completo (File Scan): Halla el Factor de Bloqueo (FB) truncando $\lfloor LB / longitud_tupla \rfloor$ y divide las tuplas totales entre el FB, redondeando hacia arriba para obtener los bloques totales.
- Evalúa el índice (si existe): Para búsquedas únicas (Clave Primaria), el coste es $X + 1$. Para búsquedas múltiples (No Agrupamiento), el coste es $X + \lceil tuplas_filtradas / FB \rceil + tuplas_filtradas$.
- Decisión: Compara el File Scan con el índice y quédate siempre con la opción de menor coste en bloques.

Fase 2: Reordenación de cruces

- Analiza las tablas disponibles y altera el orden lógico del árbol para cruzar primero aquellas que produzcan la tabla intermedia resultante más pequeña, minimizando el volumen de datos para el siguiente cruce.

Fase 3: Ejecución de las reuniones (Joins $\bowtie$)

- **Caso A - Tabla base con índice útil:** Aplica Bucle Anidado con Índice cuando una tabla viene del disco conservando sus índices. La fórmula es Coste total $= Bloques\ tabla\ externa + (Tuplas\ tabla\ externa \times Coste\ de\ UNA\ búsqueda\ en\ el\ índice)$. 'Alsa' 5 tuplas → 1+(5x14) = 71 bloques; 'Alsa' 1 tupla → 1+14 = 15
- **Caso B - Tablas intermedias sin índices:** Aplica Bucles Anidados por Bloques (BNLJ). Sitúa estrictamente la tabla con menos bloques físicos como bucle externo.
- **Cálculo BNLJ:** La fórmula general es $Coste\ total = Bloques_Externa + (\lceil Bloques_Externa / (B-2) \rceil \times Bloques_Interna)$. Si la tabla externa cabe en la memoria, el multiplicador es 1 y el coste es la suma directa de ambas tablas.

Fase 4: Coste global autobuses ocupa 40 bloques → 40+[(40/(20-2))x100] = 340 bloques

- Suma los costes definitivos de los accesos base (Fase 1) y los costes de cada cruce (Fase 3) para obtener el coste total.