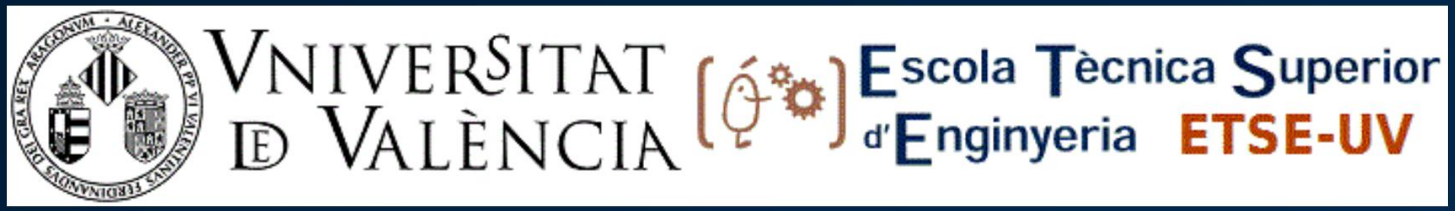
Machine Translated by Google



UNIVE RSIDAD DE VALENCIA • GRADO EN INGENIERÍA TELEMÁT ICA / INFO RMÁT ICA

2.1 Almacenamiento y Estructura de Archivos

Sistemas de Gestión de Bases de Datos (SGBD) • Profesor: Javier Sevilla

Diapositivas seleccionadas y adaptadas de Database System Concepts (Silberschatz, Korth, Sudarshan) actualizadas con discos SSD.

Machine Translated by Google

2.1. Almacenamiento y Estructura de Archivos

Visión general de los contenidos

1. Medios Físicos de Almacenamiento

- Clasificación y jerarquía de almacenamiento.
- Memorias volátiles vs no volátiles (Caché, RAM, Flash).
- Discos magnéticos tradicionales (HDD): platos, pistas y sectores.
- Discos de estado sólido (SSD) y Flash NAND: FTL, GC y TRIM.
- Sistemas RAID (Redundancia y paralelismo).
- Almacenamiento terciario (Óptico y cintas magnéticas).

2. Organización de Archivos y Gestión de Búferos

- Organización de archivos y registros (Fijos y variables).
- Organización en archivos: Heap, Secuencial y Hashing.
- Agrupación multimesa (Multitable Clustering).
- Almacenamiento del Diccionario de Datos (Catálogo).
- Niveles de acceso a datos (SGBD → Gestor de archivos → Gestor de disco).
- Gestión de búfer (Buffer Manager y reemplazo LRU).

Machine Translated by Google

1.Medios Físicos de Almacenamiento

- Classificació i jerarquia d'emmagatzematge.
- Memòries volàtils vs no volàtils (Caché, RAM, Flash).
- Discos magnètics tradicionals (HDD): plats, pistes i sectors.
- **Discos d'estat sòlid (SSD) i Flash NAND: FTL, GC i TRIM.**
- Sistemes RAID (Redundància i paral·lelisme).
- Emmagatzematge terciari (Òptic i cintes magnètiques).

Machine Translated by Google

Clasificación de los Medios Físicos de Almacenamiento

Criterios fundamentales para evaluar las tecnologías de almacenamiento

Criterios de Evaluación Clave

- Velocidad de acceso: Tiempo necesario para leer o escribir un dato requerido.
- Capacidad: Volumen total de datos que el dispositivo puede contener.
- Coste por unidad de dato: Coste económico por byte/gigabyte almacenado.
- Fiabilidad y tolerancia a fallos: Pérdida de datos frente fallos eléctricos o fallo físico del soporte.

Diferenciación por Persistencia

- Almacenamiento Volátil: Pierde su contenido inmediatamente cuando se apaga o interrumpe la alimentación eléctrica (ej. caché y memoria principal RAM).
- Almacenamiento No Volátil: El contenido se mantiene inalterado permanentemente incluso apagando el sistema. Incluye secundario (Flash, SSD, HDD), terciario (cintas, discos ópticos) y RAM con batería (NVRAM).

Machine Translated by Google

Medios Físicos de Almacenamiento (1)

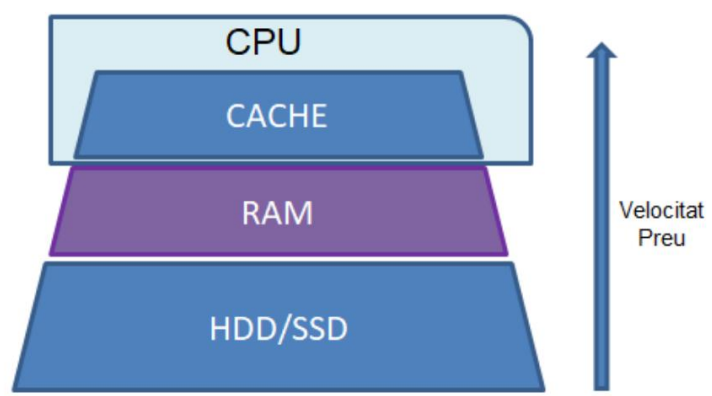
Memoria Cae (Cache) y Memoria Principal (RAM)

Memoria Cae (Cache Memory)

- Forma más rápida y costosa de almacenamiento del sistema.
- Completamente volátil (pierde el contenido sin corriente eléctrica).
- Gestionada exclusivamente por el hardware del ordenador (CPU).
- Latencias a escala de pocos nanosegundos o ciclos de reloj.
- Mantiene instrucciones y datos de uso inmediato de la CPU.

Memoria Principal (RAM)

- Acceso muy rápido (de 9ns a 12ns; 1ns= 10-9s).
- Generalmente demasiado pequeña o costosa para almacenar toda la base de datos íntegra en la mayoría de servidores.
- Volátil: se pierde si se produce un corte de energía o bloqueo.
- El SGBD transfiere bloques entre disco y RAM para poder operar con los datos.



Machine Translated by Google

Medios Físicos de Almacenamiento (2)

Características y comportamiento de la memoria Flash

Propiedades Físicas de la Memoria Flash

- Persistencia: Los datos sobreviven a cortes eléctricos (no volátil).
- Restricción de escritura: Una posición sólo se puede escribir una vez; para volver a escribir es necesario borrarla previamente.
- Límite de resistencia: Soporta un número limitado de ciclos de borrado/escritura (habitualmente 10K a 1M ciclos antes de fallar).
- Granularidad de borrado: Debe realizarse a escala de un banco/blog completo.

Rendimiento y Casos de Uso

- Velocidad de lectura: Casi tan rápida como la memoria RAM principal.
- Velocidad de escritura: Microsegundos; operación de borrado lenta (milisegundos).
- Ampliamente utilizada en móviles, llaves USB y la base de los discos SSD.
- Consolidada como el soporte de almacenamiento primario en la mayoría de servidores modernos de bases de datos.



Memoria flash INAND integrada

Fuente: https://www.sandisk.com/es-es/products/embedded-flash/automotive-inand-ufs-drives?sku=SDINDDH6-16G-XA2



Disco SSD Wester Digital 2TB

Fuente: https://rec-line.com/disco-duro-ssd-wester-digital-blue-sa510-wds200t3b0a-2tb-sata-iii-2-5

Machine Translated by Google

Medios Físicos de Almacenamiento (3)

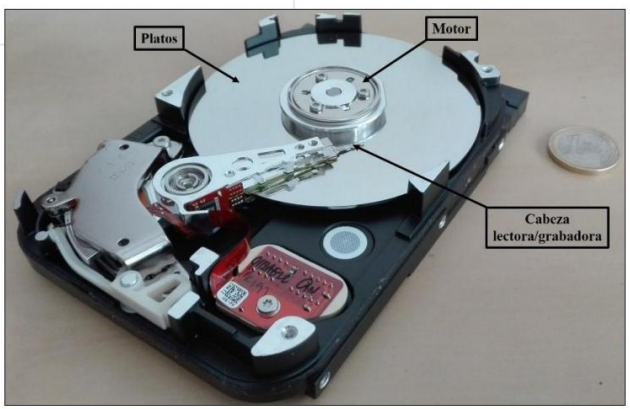
Discos magnéticos convencionales (Hard Disk Drives - HDD)

Almacenamiento en Disco Magnético

- Los datos se almacenan sobre platos que giran y se leen/escriben magnéticamente mediante cabezales.
- Medio primario clásico para el almacenamiento a largo plazo de toda la base de datos.
- Los datos deben moverse a la memoria principal para acceder-hi.
- Acceso mucho más lento que la memoria principal (orden de milisegundos).

Capacidad, Acceso y Fiabilidad

- Acceso directo: Permite leer datos del disco en cualquier orden arbitrario.
- Capacidades elevadas (hasta 36 TB) a muy bajo coste por byte.
- Persistencia garantizada frente a fallos eléctricos.
- Un fallo mecánico o rotura del cabezal puede destruir datos, pero es un evento infrecuente.



HDD Magnético

Fuente https://unpocodecienciaporfavor.com/2020/05/28/los-origenes-del-almacenamiento-de-la-informacion-vino-proceso-de-grabacion-y-lectura-de-discos-duros-magneticos/

Machine Translated by Google

Medios Físicos de Almacenamiento (4)

Discos Ópticos (CD, DVD, Blu-ray y Jukeboxes)

Características de los Discos Ópticos

- No volátiles: Datos leídos ópticamente desde un disco giratorio mediante láser.
- Formatos: CD-ROM (640 MB), DVD (4,7 a 17 GB), Blu-ray (27 a 54 GB+).
- Discos WORM (Write-Once, Read-Many) para archivo legal seguro de datos históricos (CD-R, DVD-R).

Reescritura y Sistemas Jukebox

- Versiones reescribibles (CD-RW, DVD-RW, DVD-RAM) disponibles.
- Lectura y escritura significativamente más lentas que en disco magnético o SSD (Especialmente la escritura).
- Sistemas Jukebox: Armarios robotizados con gran número de discos extraíbles para archivo de grandes volúmenes.



JukeBox óptico
Fuente: https://pc-solucion.es/optical-jukebox/

Machine Translated by Google

Medios Físicos de Almacenamiento (5)

Cintas magnéticas y copias de seguridad

Propiedades de las Cintas

- No volátiles: Utilizadas principalmente para copias de seguridad (backups) y archivo histórico.
- Acceso estrictamente secuencial: es necesario avanzar o rebobinar la cinta.
- Muy alta capacidad para cartucho (formatos Ultrium/LTO de múltiples terabytes).
- Soporte muy barato por gigabyte, unidades reproductoras de coste elevado.

Sistemas Robóticos de Cintas

- Jukeboxes y librerías de cintas para gestionar petabytes (1 petabyte = 1024 terabyte)
- Medios 'off-line': se pueden extraer y conservar en cajas de seguridad ignífugas para planes de Disaster Recovery.



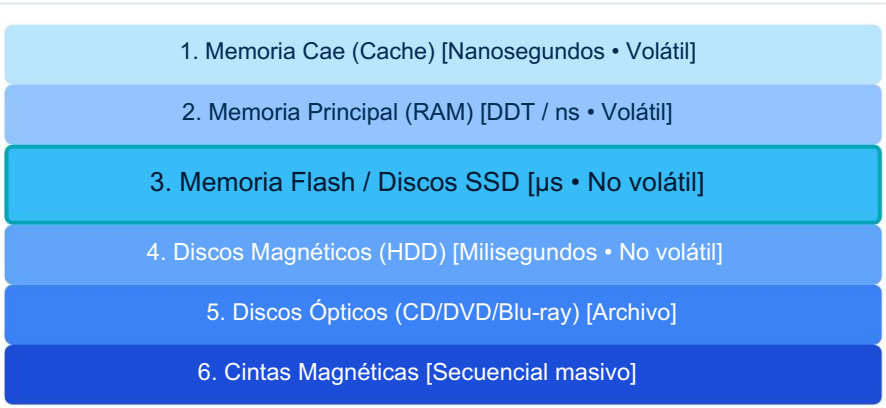
Sistema rob´toco de Cintas IBM TS4300

Fuente: https://www.server-parts.eu/post/ibm-ts-tape-library-ts2900-ts3100-ts3200-ts3310-ts3500-ts4300-ts4500-lto-storage-tape-drive

Machine Translated by Google

Jerarquía de Almacenamiento

Pirámide física de velocidad, coste y capacidad



Escalonamiento de los Discos SSD

- Almacenamiento Primario (Niveles 1 y 2): Cae y RAM. Volátiles, máxima velocidad de acceso.
- Almacenamiento Secundario (Niveles 3 y 4):
  - Nivel 3 (SSD): Acceso electrónico sin piezas móviles en microsegundos (µs).
  - Nivel 4 (HDD): Acceso mecánico limitado por giro y búsqueda en milisegundos (ms).
- Almacenamiento Terciario (Niveles 5 y 6): Óptico y cintas magnéticas.

Machine Translated by Google

Jerarquía de Almacenamiento: Detalle de los Niveles

Funciones y roles de cada nivel en el funcionamiento del SGBD

Almacenamiento Primario

- Medios más rápidos pero de naturaleza volátil (Caché, RAM).
- Destinado a los datos utilizados en el momento actual por el motor de consultas.
- Los registros y páginas deben cargar aquí antes de ser modificados o inspeccionados.

Almacenamiento secundario

- No volátil, acceso moderadamente rápido (online/on-line).
- Ejemplos: Memoria Flash, SSDs y discos magnéticos.
- Contiene la totalidad de la base de datos activa.

Almacenamiento Terciario

- No volátil, acceso lento (fuera de línea/off-line).
- Ejemplos: Cintas magnéticas y soportes ópticos.
- Para archivar versiones históricas, auditorías y copias de recuperación.

Machine Translated by Google

Mecanismo del Disco Duro Magnético (HDD)

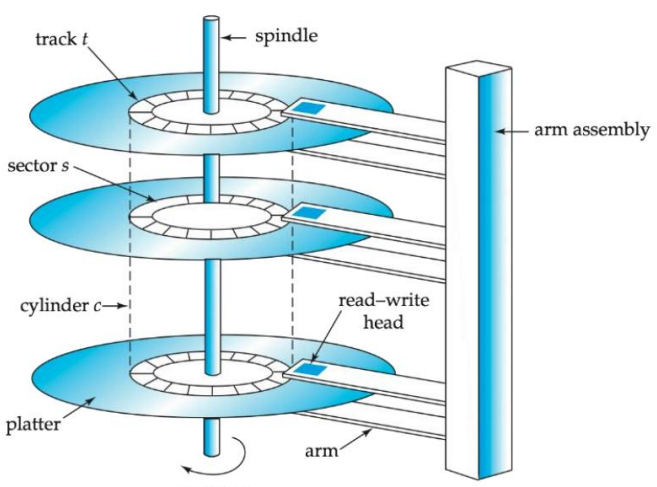
Estructura física: platos, eje, brazo y cabezales de lectura/escritura

Componentes Mecánicos Principales

- Eje (Spindle): Hace girar los platos a gran velocidad constante (5400 a 15000 rpm).
- Platos (Platters): Discos rígidos con recubrimiento magnético en ambas caras.
- Cabezal y brazo (Head & Arm): Los cabezales flotan sobre la almohada de aire microscópico generado por el giro.
- Estructura puramente mecánica sujeta a inercias.

Geometría de Disco

- Pistas (Tracks): Anillos circulares concéntricos divididos en sectores.
- Sectores: Unidad mínima de datos legibles/escribibles (512 B o 4 KB).
- Cilindro: Conjunto de pistas en la misma posición vertical en todos los platos.



Machine Translated by Google

Discos Magnéticos: Organización de la Superficie

Cabezales, pistas concéntricas, sectores y cilindros

Cabezales y pistas

- Cabezal de lectura/escritura: Posicionado extremadamente cerca de la superficie del plato.
- Lee o escribe información codificada magnéticamente.
- Más de 50.000 a 100.000 pistas por plato en discos típicos.

Sectores y Cilindros

- El brazo mueve el cabezal a la pista correcta (Seek).
- El plato gira hasta que el sector pasa debajo del cabezal (Latencia rotacional).
- Pistas exteriores contienen más sectores que los interiores.
- Cilindro: permite leer datos sin mover físicamente el brazo accionador.

Machine Translated by Google

Discos Magnéticos: Fallos y Controlador de Disco

Protección contra errores, remapeo y el papel de Disk Controller

Evolución ante Fallos

- Head-crashes: El contacto del cabezal con el plato desintegraba la capa de óxido (discos actuales mucho más protegidos).
- Sectores defectuosos individuales pueden corromperse con el tiempo.

Funciones del Disk Controller

- Interfaz de comunicación entre el bus del sistema y el disco físico (I/O en un sector, mover brazo a pista siguiente/anterior, …)
- Calcula y adjunta un checksum a cada sector para verificar integridad.
- Verificación inmediata leyendo después de escribir.
- Remapeo automático de sectores defectuosos a sectores de reserva transparentes.

Machine Translated by Google

Medidas de Rendimiento en Discos Magnéticos

Tiempo de acceso, búsqueda de pista, latencia rotacional y ancho de banda

Tiempo de Acceso (Access Time)

- Tiempo de búsqueda (Seek Time): Reposicionar físicamente el brazo sobre la pista correcta (4 a 10 ms).
- Latencia rotacional: Esperar a que el sector rote y pase debajo del cabezal (media de 1/2 vuelta: 4 a 6 ms). Depende de las RPM (7200, o 5400)
- Principal limitación de velocidad en bases de datos clásicas.

Tasa de Transferencia y Fiabilidad

- Data-transfer rate: 100 a 250+ MB/s continuos.
- MTTF: Tiempo medio de funcionamiento continuo sin fallos físicos graves (3 a 5 años).

Machine Translated by Google

Optimización del Acceso a Blogs de Disco

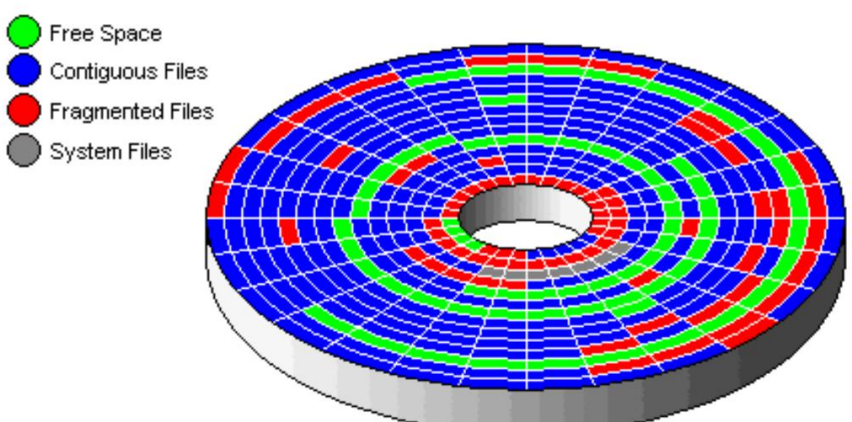
Blogs de disco, organización física y fragmentación

Contigüidad Física

- La información se recupera en unidades llamadas blogs o páginas (4 KB a 16KB.
- Organizar blogs relacionados en ubicaciones cercanas para ahorrar movimientos de brazo:
  - 1. En la misma pista.
  - 2. En el mismo cilindro.
  - 3. En cilindros adyacentes.

Fragmentación

- Con el tiempo, inserciones y eliminaciones dispersan los blogs libres.
- El acceso secuencial a un archivo fragmentado multiplica los desplazamientos del brazo del disco.
- Las herramientas de desfragmentación reorganizan los blogs por restaurar la contigüidad física.



Machine Translated by Google

Discos de Estado Sólido (SSD) — Arquitectura Interna

Almacenamiento no volátil basado en semiconductores Flash NAND

Estructura Sin Partes Móviles

- Ausencia total de componentes mecánicos: los datos se guardan en chips de memoria Flash NAND.
- Mayor resistencia física a los golpes y consumo energético mínimo.
- Silenciosos y de arranque instantáneo.
- Controlador integrado multicanal que paraleliza el acceso a los bancos NAND.

Páginas vs Blogs de Borrado

- Página (Page): Unidad mínima de escritura (programación) y lectura (4 KB a 16 KB).
- Blog (Block): Conjunto de múltiples páginas (128 a 512 páginas; 2 MB a 8 MB).
- Regla fundamental: Se puede leer y escribir a nivel de página, pero SÓLO se puede borrar a nivel de bloque entero (Erase-before-write).

Machine Translated by Google

Medidas de Rendimiento: Discos SSD frente a HDD

Comparativa de latencia, tasa de transferencia y operaciones por segundo (IOPS)

Métrica de Rendimiento	Disco Magnético (HDD)	SSD SATA III	SSD NVMe (PCIe 4.0/5.0)
Tiempo de acceso / Latencia	4 – 10 ms (Búsqueda + giro)	50 – 100 µs	10 – 30 µs (>300x más rápido!)
IOPS Aleatorias (Lectura 4KB)	100 – 200 IOPS	50.000 – 90.000 IOPS	500.000 – 1.500.000 IOPS
Tasa de transferencia continua	100 – 250 MB/s	500 – 550 MB/s	3.500 – 14.000 MB/s
Penalización por acceso disperso	Crítica (destroza el rendimiento)	Casi nula	Completamente imperceptible
Consumo y calentamiento	Alto (motores y fricción)	Muy bajo	Moderado a intenso en controladores

Conclusión para SGBD: La desaparición del Seek Time convierte a los SSD en la solución óptima para consultas con patrones de acceso aleatorio intensivo, índices secundarios (Index Scans) y uniones tipo Hash Join.

Machine Translated by Google

Impacto de los SSD en el Diseño de SGBD

Cómo cambia la arquitectura de base de datos con el uso de discos sólidos

Repercusión en Consultas e Índices

- Rebaja drástica del coste de acceso aleatorio: los Index Scans y uniones por Hash son mucho más competitivos.
- Menos dependencia del 'Clustering' físico contiguo de blogs.
- Es necesario actualizar los modelos de coste en el Optimizador de Consultas.

Motores Orientados a Flash

- Asimetría lectura/escritura: leer es barato; escribir requiere borrado de blogs y causa WAF.
- Árboles LSM (Log-Structured Merge-Trees): Motores como RocksDB o Cassandra transforman escrituras aleatorias en secuenciales continuas para proteger al SSD.
- La brecha entre RAM y NVMe es de 1 orden (10) de magnitud (ya no de 5 orders (100.000) como con HDD).

Machine Translated by Google

Sistemas RAID: Visión General

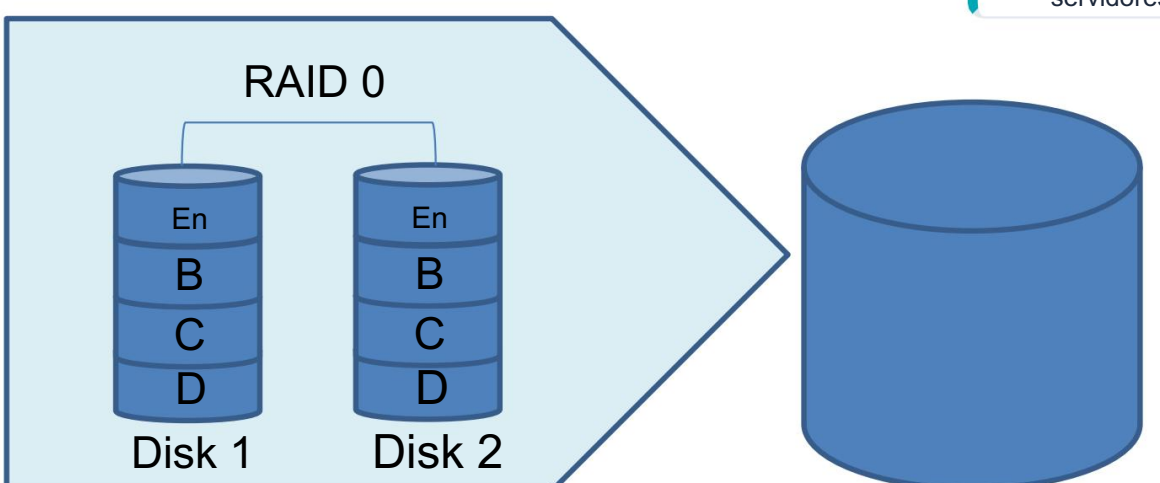
Redundante Arrays of Independent Disks

Definición y Objetivos de RAID

- Gestiona múltiples discos físicos mostrándolos como un único disco lógico de gran capacidad.
- Alta velocidad mediante el uso de discos en paralelo.
- Alta fiabilidad almacenando información de forma redundante.
- Originariamente 'Inexpensive Disks'; hoy 'Independent Disks'.

Multiplicación de Fallos

- La probabilidad de fallo crece exponencialmente con el número de discos.
- Si 1 disco tiene MTTF de 100.000 h (aprox. 11 años), un array de 100 discos tendrá un MTTF de sólo 1.000 h (aprox. 41 días!).
- Las técnicas de redundancia son imprescindibles en servidores de bases de datos.



Machine Translated by Google

Mejora de la Fiabilidad Mediante Redundancia

Almacenamiento redundante, réplica en espejo (Mirroring) y MTTDL

Espejo (Mirroring o Shadowing)

- Duplicación de cada disco físico en dos discos idénticos.
- Cada escritura se ejecuta obligatoriamente en ambos discos.
- Las lecturas se pueden repartir entre cualquiera de los dos discos.
- Si falla un disco, los datos continúan totalmente accesibles desde del otro.

MTTDL (Tiempo hasta la Pérdida) (Mean Time To Data Loss)

- Pérdida sólo si falla el disco espejo antes de haber reparado el primero.
- Probabilidad muy baja para fallos independientes.
- Con MTTF de 100.000 hy MTTR (Time Repair) de 10 h, el MTTDL alcanza 57.000 años!). (Esto es verdad si el disco con problemas se cambia por uno nuevo a las 10h, la probabilidad de que se rompa el segundo en 10h es muy , muy baja)

Machine Translated by Google

Mejora del Rendimiento Mediante Paralelismo

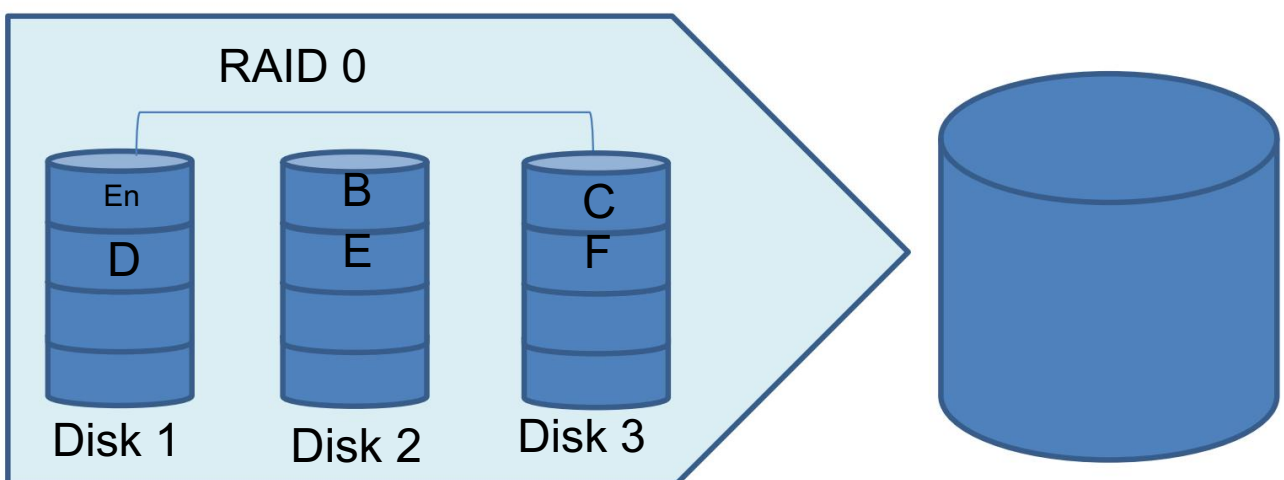
Balance de carga, fragmentación de datos (Striping) a nivel de bit y de bloque

Objetivos del Paralelismo

- 1. Balance de carga: Atender muchos accesos pequeños independientes simultáneamente (dispara el Throughput).
- 2. Paralelizar accesos grandes: Reduce el tiempo de respuesta individual.

Modalidades de Striping

- Nivel de bit: Divide los bits de cada byte entre discos (en desuso).
- Nivel de blog (Block Level Striping) : Con n discos, el blog y se escribe en el (y mod n) +1 disco. Permite consultas simultáneas sobre distintos bloques.



Block Level Striping

Machine Translated by Google

Cintas Magnéticas: Formatos y Roles

Formatos comerciales, tasas de transferencia y aplicaciones

Capacidad y Formatos

- Grandes volúmenes de datos y alta tasa de transferencia una vez posicionado el cabezal.
- Formatos: DAT, DLT, Ultrium/LTO (hasta 30 TB+ por cinta).
- Tasas de transferencia de decenas a cientos de MB/s.
- Soporte muy barato por gigabyte.

Limitaciones y Casos de Uso

- Acceso muy lento debido a la naturaleza estrictamente secuencial. •

Uso para copias de seguridad periódicas (backups) y archivo histórico.

- Librerías jukebox masivas que gestionan petabytes

Machine Translated by Google

2. Organización de Archivos y Gestión de Búferos

- Organització de fitxers i registres (Fixos i variables).
- Organització en fitxers: Heap, Seqüencial i Hashing.
- Agrupament multitaula (Multitable Clustering).
- Emmagatzematge del Diccionari de Dades (Catàleg).
- Nivells d'accés a dades (SGBD → Gestor de fitxers → Gestor de disc).
- Gestió de memòria intermèdia (Buffer Manager i reemplaçament LRU).

Machine Translated by Google

Organización de Archivos

Archivos como secuencias de registros (Fijos vs Variables)

Estructura Básica y Registros Fijos

- La BD se almacena como una colección de archivos físicos.
- Cada archivo es una secuencia de registros; cada registro, una secuencia de campos.
- Registros Fijos (Fixed-length) (1ª Aproximación: simple):
  - Tamaño de registro constante.
  - Cada archivo contiene sólo registros de un tipo.
  - Se usan archivos separados para cada tabla relacional.

Registros de Tamaño Variable

- Surgen por campos alfanuméricos variables (VARCHAR, TEXTO, BLOB).
- Almacenamiento de múltiples tipos de registros en un mismo archivo.
- Campos repetitivos o colecciones.
- Requieren marcadores de fin o ranuras internas para saber dónde comienza y termina cada campo.

Machine Translated by Google

Organización de Registros en Archivos

Heap (pila), secuencial ordenado, hashing y clustering multimesa

Métodos de Organización Clásicos

- Pila (Heap): Un registro se guarda en cualquier bloque libre del archivo (inserción muy rápida).
- Secuencial (Ordered): Guardados ordenados según la clave de búsqueda (óptimo para consultas por rango).
- Hashing: Una función hash aplicada a cierto campo determina el blog exacto donde alojar el registro.

Agrupación Multimesa (Clustering)

- Registros de diferentes relaciones se alojan juntos en el mismo blog si tienen vínculos frecuentes.
- Ejemplo: Un cliente y todos sus pedidos en el mismo blog de disco.
- Motivación: Minimizar las operaciones de E/S (I/O) al resolver consultas con JOIN.

Machine Translated by Google

Almacenamiento del Diccionario de Datos

Catálogo del sistema y persistencia de los metadatos

¿Qué contiene el Diccionario?

- Nombres de relaciones, tipos y longitud de los atributos de cada campo.
- Definiciones y nombres de vistas (views).
- Restricciones de integridad (claves primarias, foráneas, CHECK).
- Información de usuarios, roles y claves de seguridad.

Estadísticas y Ubicación

- Datos estadísticos: número de tuplas, factores de bloqueo (clave para el optimizador).
- Organización física de los archivos (secuencial, hash, etc.) y posición.
- Información sobre los índices definidos (cap. 11).
- El catálogo se almacena internamente como un conjunto más de tablas relacionales.

Machine Translated by Google

Acceso a la Información de una BD (Storage Access 1)

Peticiones de registros, gestor de archivos y concepto de página

Peticiones de Registros desde el SGBD

- El SGBD decide el registro que necesita y lo pide al Gestor de Archivos.
- Para el SGBD, la BD es concebida simplemente como una colección de registros almacenados.
- El SGBD no interactúa con los bloques físicos concretos del hardware.

El Gestor de Archivos y la Página

- El Gestor de Archivos trata los archivos como una colección de páginas.
- Página (o blog): Unidad indivisible de E/S que se transfiere entre disco y RAM (4 KB a 8 KB).
- Cada página tiene asignado un identificador único (PageID).

Machine Translated by Google

Acceso a la Información de una BD (Storage Access 2)

Localización de páginas y papel del Gestor de Disco

Del Gestor de Archivos en el Disco

- El Gestor de Archivos decide en qué página concreta está alojado el registro y la solicita al Gestor de Disco.
- A menudo es necesario sustituir o complementar el administrador de archivos genérico del SO para garantizar escrituras inmediatas sin caches ocultas.

Responsabilidades del Gestor de Disco

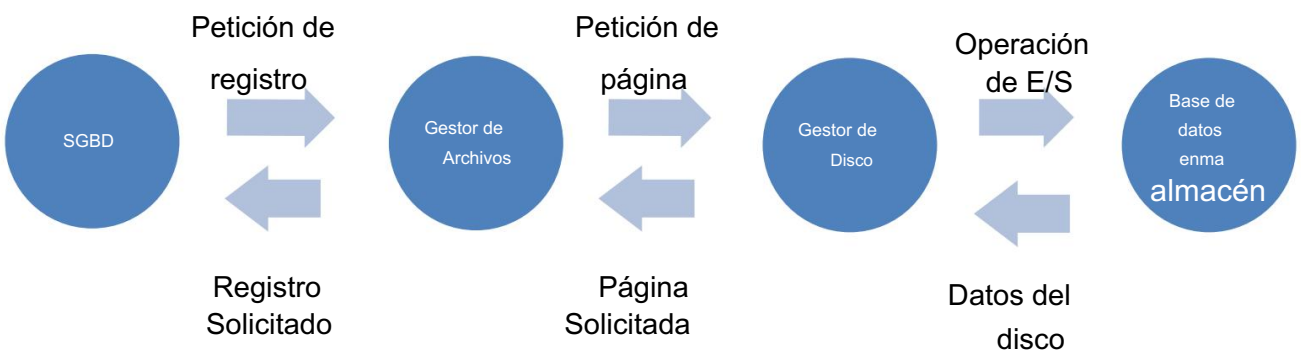
- Determina la ubicación física real de la página en el medio (dirección LBA/cilindro-pista).
- Ejecuta las operaciones físicas de E/S necesarias para leer o escribir la página.

Machine Translated by Google

Flujo de Acceso a la Información en la BD

Interacción entre capas: SGBD ↔ Gestor de Archivos ↔ Gestor de Disco ↔ Disco

- 1. Petición de registro: El SGBD solicita un registro lógico al Gestor de Archivos.
- 2. Petición de página: El Gestor de Archivos calcula en qué página se encuentra y la pide al Gestor de Disco.
- 3. Operación de E/S: El Gestor de Disco tramita la lectura del blog de disco de la base de datos almacenada.
- 4. Retorno ascendente: La página se carga a memoria, el Gestor de Archivos extrae el registro exacto y la entrega al SGBD.



Machine Translated by Google

Acceso al Almacenamiento y Memoria Intermedia

Minimización de transferencias entre disco y memoria RAM

Blogs de Archivo y Transferencia

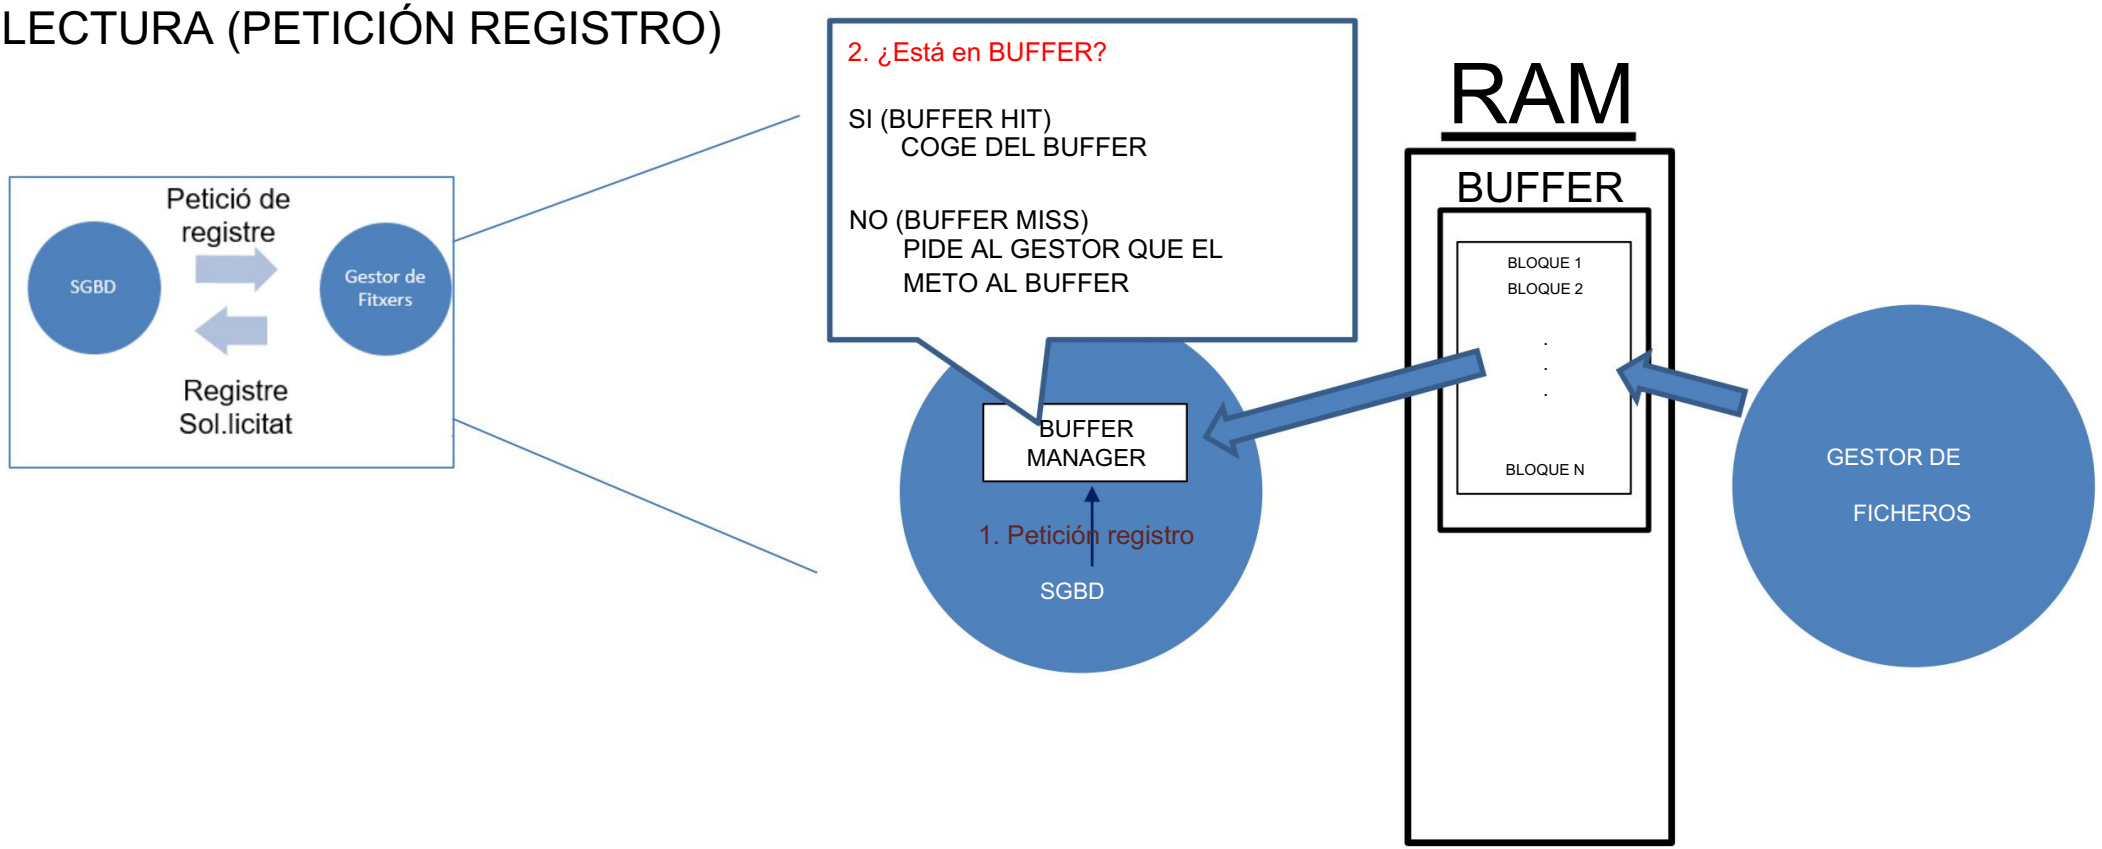
- El archivo de base de datos está dividido en bloques. Los blogs son la unidad tanto de asignación de almacenamiento como de transferencia.
- READ: Transfiere datos de disco hacia la memoria RAM.
- WRITE: Transfiere datos de RAM hacia el disco físico.

Objetivo del SGBD y Búfers

- Minimizar operaciones de E/S manteniendo en memoria principal tantos bloques como sea posible.
- Búfer (Buffer): Porción de RAM destinada a guardar copias de blogs de disco.
- Buffer Manager: Subsistema encargado de asignar y administrar el espacio de búferes.

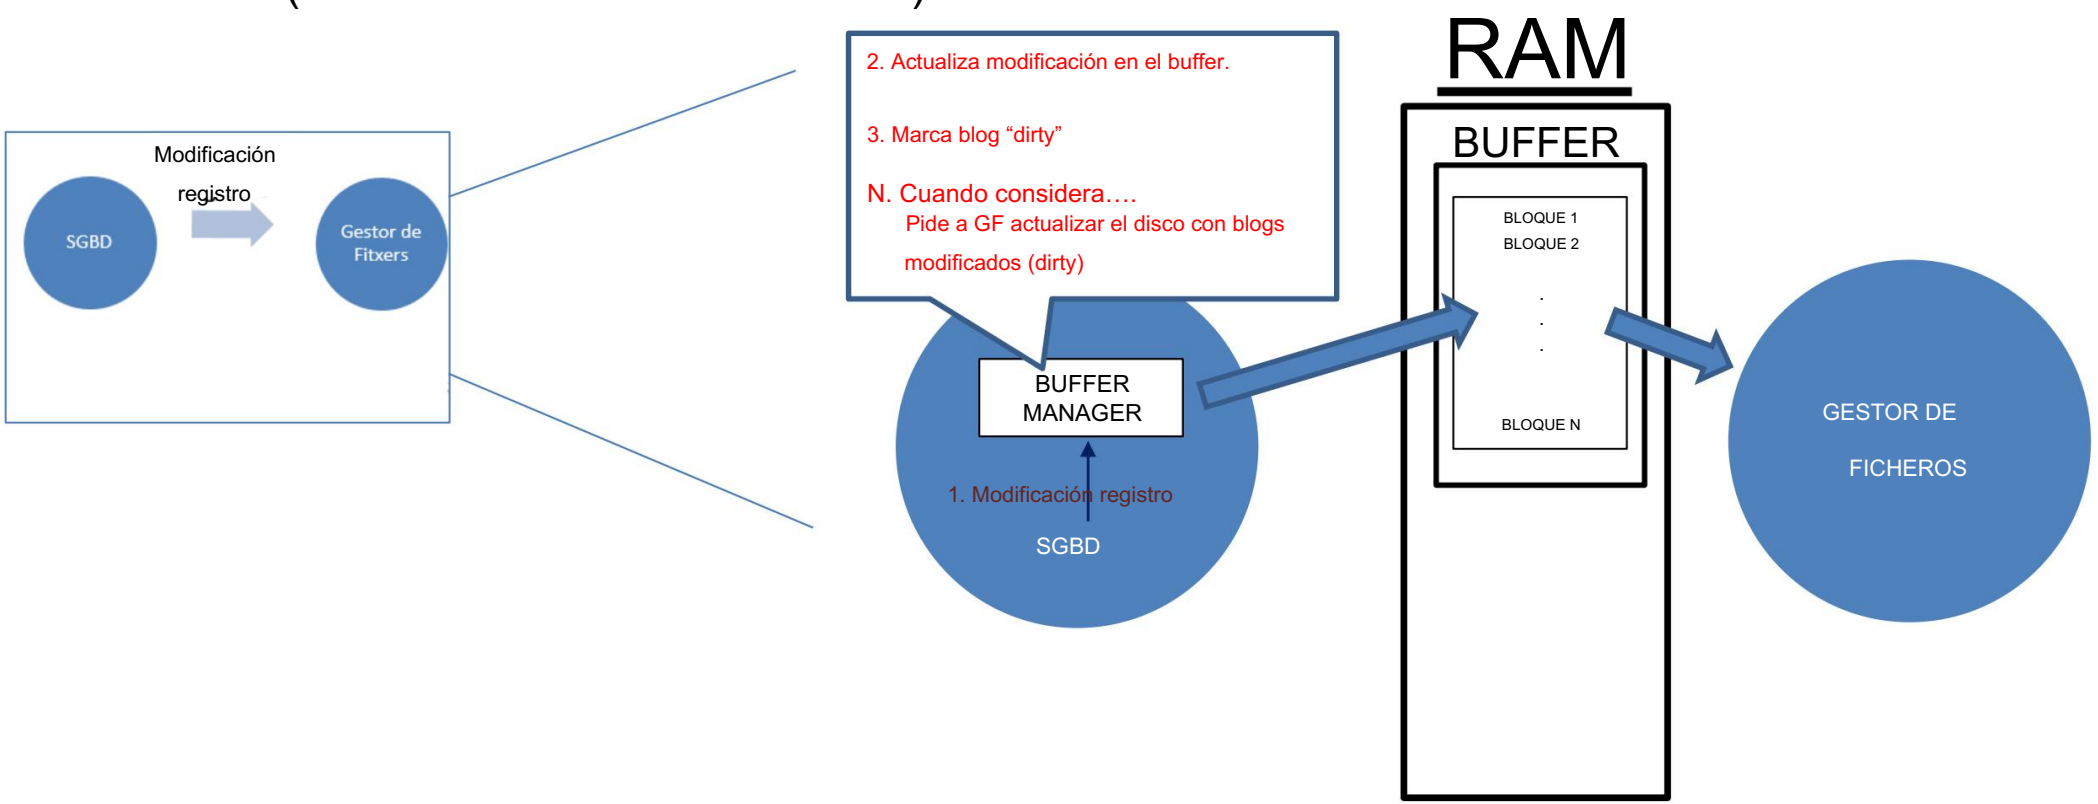
Machine Translated by Google

LECTURA (PETICIÓN REGISTRO)



Machine Translated by Google

ESCRITURA (MODIFICACIÓN REGISTRO)

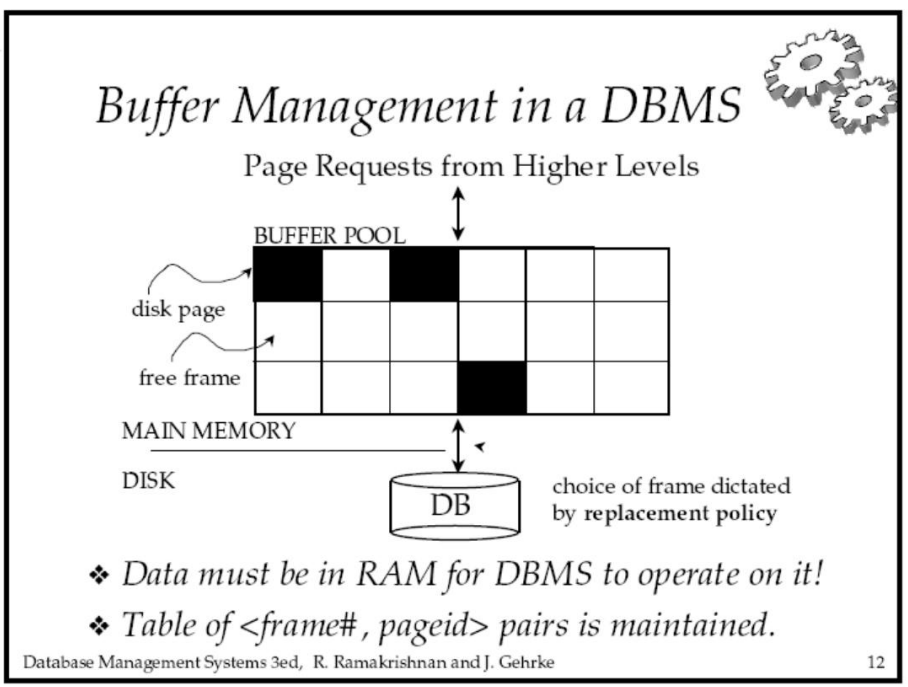


Machine Translated by Google

Gestión de la Memoria Intermedia (Buffer Management)

Organización del Buffer Pool, marcos (frames) y correspondencia con disco

- Requisito innegociable: ¡ Los datos deben estar en memoria RAM para que el SGBD pueda operar directamente!
- Buffer Pool dividido en marcos (frames) de tamaño exacto en una página de disco.
- Tabla de marcos: El SGBD mantiene una mesa interna con los pares <frame#, pageid>.
- Marcos libres y ocupados (con páginas limpias o sucias).
- La elección del marco para desalojar una página viene dictada por la política de sustitución (ej. LRU).



Machine Translated by Google

Funcionamiento del Gestor de Búferes (Buffer Manager)

Cómo atiende las solicitudes: Buffer Hit vs Buffer Miss

Buffer Hit (Ya residente)

- Si el blog requerido ya está residente en algún marco de la búfer:
- El Gestor de Búfers devuelve directamente la dirección de memoria RAM donde se encuentra el blog.
- Cero operaciones de E/S a disco físico (máxima velocidad).

Buffer Miss (No residente)

- 1. Asigna espacio en el búfer para el nuevo blog.
- 2. Si todos los marcos están llenos, desaloja otro bloque siguiendo la política de reemplazo.
- 3. El blog sustituido sólo se escribe a disco si ha sido modificado (página sucia o dirty).
- 4. Lee el blog solicitado desde el disco al marco liberado.

Machine Translated by Google

Políticas de Reemplazo de Búferos

Estrategia LRU, limitaciones en SGBD y bloques anclados (Pinned Blocks)

La Estrategia LRU (Least Recently Used)

- Reemplaza el bloque utilizado hace más tiempo (basado en el patrón pasado como predictor).
- En escaneados secuenciales completos de tablas grandes, LRU puede expulsar páginas útiles por blogs que sólo se leerán una vez.
- Los sistemas suelen usar estrategias mixtas con pistas del optimizador.

Blogs Anclados y Escritura Forzada

- Blog anclado (Pinned Block): Blog en memoria que tiene prohibido ser expulsado mientras se está modificando por una transacción.
- Se mantiene un contador (Pin Count); sólo se libera cuando llega a cero.
- Forced Output: Fuerza la escritura inmediata a disco por razones de recuperación (WAL).

Machine Translated by Google

Ejercicio Práctico: Gestión de Búferes (Enunciado)

Traza de operaciones concurrentes de usuarios con una capacidad de 3 páginas o marcos

Secuencia de Operaciones de Usuarios

- 1. U1: lee de la página B de la BD
- 2. U1: lee de la página C
- 3. U1: modifica/escribe en la página C (nueva versión c2)
- 4. U2: lee de la página B
- 5. U1: lee de la página A
- 6. U2: lee de la página D
- 7. U2: modifica/escribe en la página D (nueva versión d2)
- 8. U3: lee de la página D
- 9. U1: lee de la página E
- 10. U1: escribe en la página E (versión e2)
- 11. U2: lee de la página F

Estado Inicial del Sistema

Base de Datos a disco: A=a1, B=b1, C=c1, D=d1, E=e1, F=f1

Espacio de Búfers (3 marcos inicialmente vacíos en RAM):

Marco 1	Marco 2	Marco 3
[vacío]	[vacío]	[vacío]

Usuarios activos: U1, U2 y U3 concurrentemente.

Machine Translated by Google

Ejercicio Práctico: Resolución de la Traza de los Búferos

Evolución paso a paso de los marcos de memoria y escritura de páginas sucias (*) a disco

Paso	Marco 1	Marco 2	Marco 3	Acción / Observación LRU
1. U1 lee B	1: B=b1	2: -	3: -	Carga B a Marco 1
2. U1 lee C	1: B=b1	2: C=c1	3: -	Carga C a Marco 2
3. U1 mod C (c2)	1: B=b1	2: C=c2 *	3: -	Marca C como sucia (*)
4. U2 lee B	1: B=b1	2: C=c2 *	3: -	Hit de B (se actualiza LRU de B)
5. U1 lee A	1: B=b1	2: C=c2 *	3: A=a1	Carga A a Marco 3 (Búfer lleno)
6. U2 lee D	1: D=d1	2: C=c2 *	3: A=a1	Expulsa B (menos usado). B estaba limpia, no se escribe a disco
7. U2 mod D (d2)	1: D=d2 *	2: C=c2 *	3: A=a1	Modifica D en RAM (sucia *)
8. U3 lee D	1: D=d2 *	2: C=c2 *	3: A=a1	Hit de D (se actualiza LRU de D)
9. U1 lee E	1: D=d2 *	2: C=c2 *	3: E=e1	Expulsa A (LRU). Carga E
10. U1 escribe E (e2)	1: D=d2 *	2: C=c2 *	3: E=e2 *	Modifica E en RAM (sucia *)
11. U2 lee F	1: D=d2 *	2: F=f1	3: E=e2 *	¡Expulsa C! Puesto que C estaba sucia (*), SE ESCRIBE C=c2 A DISCO!