


UNIVERSITAT DE VALÈNCIA • GRAU EN ENGINYERIA TELEMÀTICA / INFORMÀTICA

# 2.1 Emmagatzematge i Estructura de Fitxers

Sistemes de Gestió de Bases de Dades (SGBD) • Professor: Javier Sevilla

*Diapositives seleccionades i adaptades de Database System Concepts (Silberschatz, Korth, Sudarshan) actualitzades amb discs SSD.*

# 2.1. Emmagatzematge i Estructura de Fitxers

Visió general dels continguts

### 1. Mitjans Físics d'Emmagatzematge

- Classificació i jerarquia d'emmagatzematge.
- Memòries volàtils vs no volàtils (Caché, RAM, Flash).
- Discos magnètics tradicionals (HDD): plats, pistes i sectors.
- Discos d'estat sòlid (SSD) i Flash NAND: FTL, GC i TRIM.
- Sistemes RAID (Redundància i paral·lelisme).
- Emmagatzematge terciari (Òptic i cintes magnètiques).

### 2. Organització de Fitxers i Gestió de Búfers

- Organització de fitxers i registres (Fixos i variables).
- Organització en fitxers: Heap, Seqüencial i Hashing.
- Agrupament multitaula (Multitable Clustering).
- Emmagatzematge del Diccionari de Dades (Catàleg).
- Nivells d'accés a dades (SGBD → Gestor de fitxers → Gestor de disc).
- Gestió de memòria intermèdia (Buffer Manager i reemplaçament LRU).

# 1.Mitjans Físics d'Emmagatzematge

- Classificació i jerarquia d'emmagatzematge.
- Memòries volàtils vs no volàtils (Caché, RAM, Flash).
- Discos magnètics tradicionals (HDD): plats, pistes i sectors.
- **Discos d'estat sòlid (SSD) i Flash NAND: FTL, GC i TRIM.**
- Sistemes RAID (Redundància i paral·lelisme).
- Emmagatzematge terciari (Òptic i cintes magnètiques).

# Classificació dels Mitjans Físics d'Emmagatzematge

Criteris fonamentals per avaluar les tecnologies d'emmagatzematge

## Criteris d'Avaluació Clau

- **Velocitat d'accés:** Temps necessari per a llegir o escriure una dada requerida.
- **Capacitat:** Volum total de dades que el dispositiu pot contindre.
- **Cost per unitat de dada:** Cost econòmic per byte/gigabyte emmagatzemat.
- **Fiabilitat i tolerància a fallades:** Pèrdua de dades davant fallades elèctriques o fallada física del suport.

## Diferenciació per Persistència

- **Emmagatzematge Volàtil:** Perd el seu contingut immediatament quan s'apaga o s'interromp l'alimentació elèctrica (ex. memòria cau i memòria principal RAM).
- **Emmagatzematge No Volàtil:** El contingut es manté inalterat permanentment fins i tot apagant el sistema. Inclou secundari (Flash, SSD, HDD), terciari (cintes, discs òptics) i RAM amb bateria (NVRAM).

# Mitjans Físics d'Emmagatzematge (1)

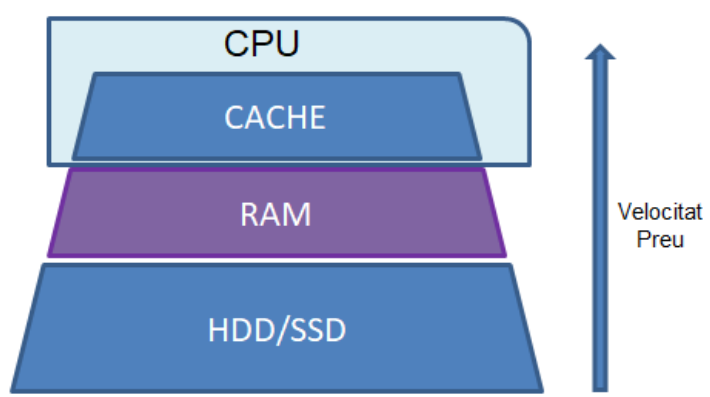
Memòria Cau (Cache) i Memòria Principal (RAM)

## Memòria Cau (Cache Memory)

- Forma més ràpida i costosa d'emmagatzematge del sistema.
- Completament volàtil (perd el contingut sense corrent elèctric).
- Gestionada exclusivament pel maquinari de l'ordinador (CPU).
- Latències a escala de pocs nanosegons o cicles de rellotge.
- Manté instruccions i dades d'ús immediat de la CPU.

## Memòria Principal (RAM)

- Accés molt ràpid (de 9ns a 12ns; 1 ns= $10^{-9}$s).
- Generalment massa menuda o costosa per a emmagatzemar tota la base de dades íntegra en la majoria de servidors.
- Volàtil: es perd si es produïx un tall d'energia o bloqueig.
- El SGBD transferix **blocs** entre disc i RAM per poder operar amb les dades.



# Mitjans Físics d'Emmagatzematge (2)

Característiques i comportament de la memòria Flash

## Propietats Físiques de la Memòria Flash

- Persistència: Les dades sobreviuen a talls elèctrics (no volàtil).
- Restricció d'escriptura: Una posició només es pot escriure una vegada; per a tornar a escriure-hi cal esborrar-la prèviament.
- Límit de resistència: Suporta un nombre limitat de cicles d'esborrat/escriptura (habitualment 10K a 1M cicles abans de fallar).
- Granularitat d'esborrat: S'ha de fer a escala d'un banc/bloc complet.

## Rendiment i Casos d'Ús

- **Velocitat** de lectura: Quasi tan ràpida com la memòria RAM principal.
- **Velocitat** d'escriptura: Microsegons; operació d'esborrat lenta (mil·lisegons).
- Àmpliament utilitzada en mòbils, claus USB i la base dels discos SSD.
- Consolidada com el suport d'emmagatzematge primari en la majoria de servidors moderns de bases de dades.




Memoria flash INAND integrada
Fuente: https://www.sandisk.com/es-es/products/embedded-flash/automotive-inand-ufs-drives?sku=SDINDDH6-16G-XA2




Disco SSD Wester Digital 2TB
Fuente: https://rec-line.com/disco-duro-ssd-wester-digital-blue-sa510-wds200t3b0a-2tb-sata-iii-2-5

# Mitjans Físics d'Emmagatzematge (3)

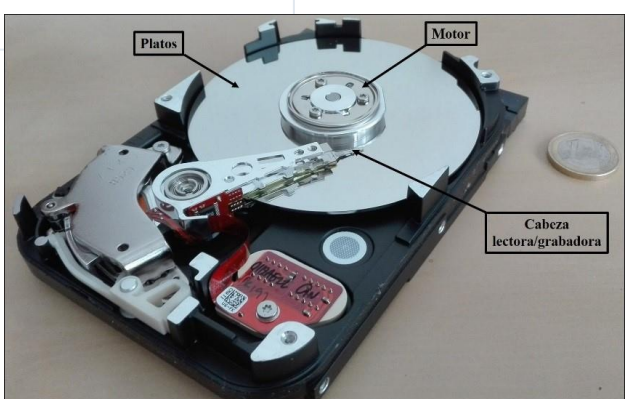
Discos magnètics convencionals (Hard Disk Drives - HDD)

## Emmagatzematge en Disc Magnètic

- Les dades s'emmagatzemen sobre plats que giren i es llegeixen/escriuen magnèticament mitjançant capçals.
- Mitjà primari clàssic per a l'emmagatzematge a llarg termini de tota la base de dades.
- Les dades s'han de moure a la memòria principal per accedir-hi.
- Accés molt més lent que la memòria principal (ordre de mil·lisegons).

## Capacitat, Accés i Fiabilitat

- Accés directe: Permet llegir dades del disc en qualsevol ordre arbitrari.
- Capacitats elevades (fins 36 TB) a molt baix cost per byte.
- Persistència garantida davant fallades elèctriques.
- Una fallada mecànica o trencament del capçal pot destruir dades, però és un esdeveniment infreqüent.




HDD Magnético

Fuente https://unpocodecienciaporfavor.com/2020/05/28/los-origenes-del-almacenamiento-de-la-informacion-vi-proceso-de-grabacion-y-lectura-de-discos-duros-magneticos/

# Mitjans Físics d'Emmagatzematge (4)

Discos Òptics (CD, DVD, Blu-ray i Jukeboxes)

## Característiques dels Discos Òptics

- No volàtils: Dades llegides òpticament des d'un disc giratori mitjançant làser.
- Formats: CD-ROM (640 MB), DVD (4,7 a 17 GB), Blu-ray (27 a 54 GB+).
- Discos WORM (Write-Once, Read-Many) per a arxivament legal segur de dades històriques (CD-R, DVD-R).

## Reescriptura i Sistemes Jukebox

- Versions reescrivibles (CD-RW, DVD-RW, DVD-RAM) disponibles.
- Lectura i escriptura significativament més lentes que en disc magnètic o SSD (Especialment la escriptura).
- Sistemes Jukebox: Armaris robotitzats amb gran nombre de discs extraïbles per a arxiu de grans volums.



JukeBox óptico
Fuente: https://pc-solucion.es/optical-jukebox/

# Mitjans Físics d'Emmagatzematge (5)

Cintes magnètiques i còpies de seguretat

## Propietats de les Cintes

- No volàtils: Utilitzades principalment per a còpies de seguretat (backups) i arxiu històric.
- Accés estrictament seqüencial: cal avançar o rebobinar la cinta.
- Molt alta capacitat per cartutx (formats Ultrium/LTO de múltiples terabytes).
- Suport molt barat per gigabyte, unitats reproductores de cost elevat.

## Sistemes Robòtics de Cintes

- Jukeboxes i llibreries de cintes per a gestionar petabytes (1 petabyte = 1024 terabyte)
- Medis 'off-line': es poden extraure i conservar en caixes de seguretat ignífugues per a plans de Disaster Recovery.



Sistema rob´toco de Cintas IBM TS4300
Fuente: https://www.server-parts.eu/post/ibm-ts-tape-library-ts2900-ts3100-ts3200-ts3310-ts3500-ts4300-ts4500-lto-storage-tape-drive

# Jerarquia d'Emmagatzematge

Piràmide física de velocitat, cost i capacitat




## Esglaonament dels Discos SSD

- **Emmagatzematge Primari (Nivells 1 i 2):** Cau i RAM. Volàtils, màxima velocitat d'accés.
- **Emmagatzematge Secundari (Nivells 3 i 4):**
  - **Nivell 3 (SSD):** Accés electrònic sense peces mòbils en microsegons (µs).
  - **Nivell 4 (HDD):** Accés mecànic limitat per gir i cerca en mil·lisegons (ms).
- **Emmagatzematge Terciari (Nivells 5 i 6):** Òptic i cintes magnètiques.

# Jerarquia d'Emmagatzematge: Detall dels Nivells

Funcions i rols de cada nivell en el funcionament del SGBD

### Emmagatzematge Primari

- Medis més ràpids però de naturalesa volàtil (Caché, RAM).
- Destinat a les dades utilitzades en el moment actual pel motor de consultes.
- Els registres i pàgines s'han de carregar ací abans de ser modificats o inspeccionats.

### Emmagatzematge Secundari

- No volàtil, accés moderadament ràpid (en línia / on-line).
- Exemples: Memòria Flash, SSDs i discs magnètics.
- Conté la totalitat de la base de dades activa.

### Emmagatzematge Terciari

- No volàtil, accés lent (fora de línia / off-line).
- Exemples: Cintes magnètiques i suports òptics.
- Per a arxivar versions històriques, auditories i còpies de recuperació.

# Mecanisme del Disc Dur Magnètic (HDD)

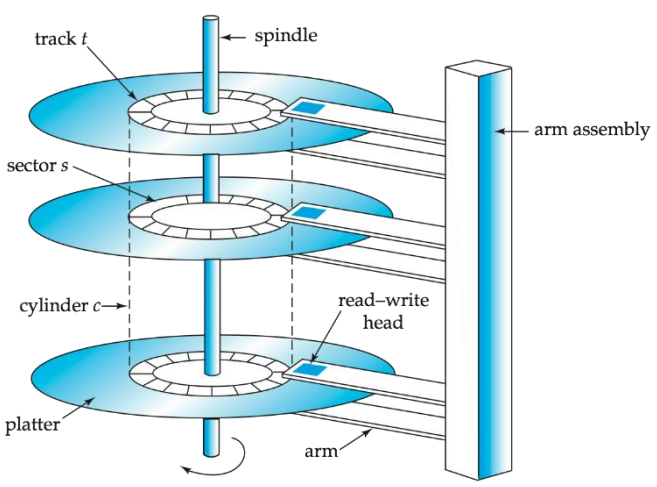
Estructura física: plats, eix, braç i capçals de lectura/escriptura

## Components Mecànics Principals

- **Eix (Spindle):** Fa girar els plats a gran velocitat constant (5400 a 15000 rpm).
- **Plats (Platters):** Discos rígids amb recobriment magnètic a ambdues cares.
- **Capçal i braç (Head & Arm):** Els capçals suren sobre el coixí d'aire microscòpic generat pel gir.
- Estructura purament mecànica subjecta a inèrcies.

## Geometria de Disc

- **Pistes (Tracks):** Anells circulars concèntrics dividits en sectors.
- **Sectors:** Unitat mínima de dades llegibles/escrivibles (512 B o 4 KB).
- **Cilindre:** Conjunt de pistes en la mateixa posició vertical en tots els plats.



# Discos Magnètics: Organització de la Superfície

Capçals, pistes concèntriques, sectors i cilindres

## Capçals i Pistes

- Capçal de lectura/escriptura: Posicionat extremadament a prop de la superfície del plat.
- Llig o escriu informació codificada magnèticament.
- Més de 50.000 a 100.000 pistes per plat en discs típics.

## Sectors i Cilindres

- El braç mou el capçal a la pista correcta (Seek).
- El plat gira fins que el sector passa davall del capçal (Latència rotacional).
- Pistes exteriors contenen més sectors que les interiors.
- Cilindre: permet llegir dades sense moure físicament el braç accionador.

# Discos Magnètics: Fallades i Controlador de Disc

Protecció contra errors, remapeig i el paper del Disk Controller

## Evolució davant Fallades

- Head-crashes: El contacte del capçal amb el plat desintegrava la capa d'òxid (discs actuals molt més protegits).
- Sectors defectuosos individuals poden corrompre's amb el temps.

## Funcions del Disk Controller

- Interfície de comunicació entre el bus del sistema i el disc físic (I/O en un sector, moure braç a pista seguent/anterior, ...)
- Calcula i adjunta un checksum a cada sector per verificar integritat.
- Verificació immediata llegint després d'escriure.
- Remapeig automàtic de sectors defectuosos a sectors de reserva transparents.

# Mesures de Rendiment en Discs Magnètics

Temps d'accés, cerca de pista, latència rotacional i ample de banda

## Temps d'Accés (Access Time)

- **Temps de cerca (Seek Time):** Reposicionar físicament el braç sobre la pista correcta (4 a 10 ms).
- **Latència rotacional:** Esperar que el sector rote i passe davall del capçal (mitjana d'1/2 volta: 4 a 6 ms). Depen de les RPM (7200, o 5400)
- Principal limitació de velocitat en bases de dades clàssiques.

## Taxa de Transferència i Fiabilitat

- **Data-transfer rate:** 100 a 250+ MB/s continus.
- **MTTF:** Temps mitjà de funcionament continu sense fallades físiques greus (3 a 5 anys).

# Optimització de l'Accés a Blocs de Disc

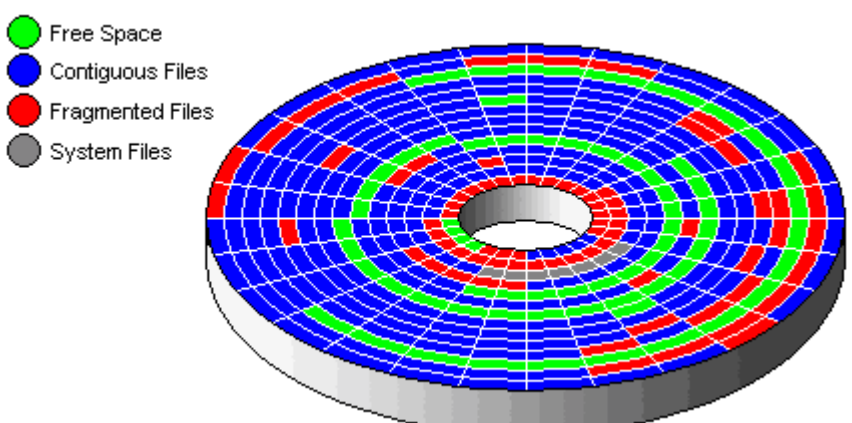
Blocs de disc, organització física i fragmentació

## Contigüitat Física

- La informació es recupera en unitats anomenades blocs o pàgines (4 KB a 16KB.
- Organitzar blocs relacionats en ubicacions properes per estalviar moviments de braç:
  - 1. A la mateixa pista.
  - 2. Al mateix cilindre.
  - 3. En cilindres adjacents.

## Fragmentació

- Amb el temps, insercions i eliminacions dispersen els blocs lliures.
- L'accés seqüencial a un fitxer fragmentat multiplica els desplaçaments del braç del disc.
- Les eines de desfragmentació reorganitzen els blocs per restaurar la contigüitat física.



# Discos d'Estat Sòlid (SSD) — Arquitectura Interna

Emmagatzematge no volàtil basat en semiconductors Flash NAND

## Estructura Sense Parts Mòbils

- **Absència total de components mecànics**: les dades es guarden en xips de memòria Flash NAND.
- Major resistència física als colps i consum energètic mínim.
- Silenciosos i d'arrancada instantània.
- Controlador integrat multicanal que paral·lelitza l'accés als bancs NAND.

## Pàgines vs Blocs d'Esborrat

- **Pàgina (Page):** Unitat mínima d'escriptura (programació) i lectura (4 KB a 16 KB).
- **Bloc (Block):** Conjunt de múltiples pàgines (128 a 512 pàgines; 2 MB a 8 MB).
- **Regla fonamental:** Es pot llegir i escriure a nivell de pàgina, però NOMÉS es pot esborrar a nivell de bloc sencer (*Erase-before-write*).

# Mesures de Rendiment: Discos SSD enfront de HDD

Comparativa de latència, taxa de transferència i operacions per segon (IOPS)

| Mètrica de Rendiment | Disc Magnètic (HDD) | SSD SATA III | SSD NVMe (PCIe 4.0/5.0) |
|---|---|---|---|
| **Temps d'accés / Latència** | 4 - 10 ms (Cerca + gir) | 50 - 100 µs | **10 – 30 µs (>300x més ràpid!)** |
| **IOPS Aleatòries (Lectura 4KB)** | 100 - 200 IOPS | 50.000 - 90.000 IOPS | **500.000 – 1.500.000 IOPS** |
| **Taxa de transferència contínua** | 100 - 250 MB/s | 500 - 550 MB/s | 3.500 - 14.000 MB/s |
| **Penalització per accés dispers** | **Crítica (destrossa el rendiment)** | Quasi nul·la | Completament imperceptible |
| **Consum i escalfament** | Alt (motors i fricció) | Molt baix | Moderat a intens en controladors |

**Conclusió per a SGBD: La desaparició del Seek Time convertix els SSD en la solució òptima per a consultes amb patrons d'accés aleatori intensiu, índexs secundaris (Index Scans) i unions tipus Hash Join.**

# Impacte dels SSD en el Disseny de SGBD

Com canvia l'arquitectura de base de dades amb l'ús de discos sòlids

## Repercussió en Consultes i Índexs

- Rebaixa dràstica del cost d'accés aleatori: els Index Scans i unions per Hash són molt més competitius.
- Menys dependència del 'Clustering' físic contigu de blocs.
- Cal actualitzar els models de cost a l'Optimitzador de Consultes.

## Motors Orientats a Flash

- Asimetria lectura/escriptura: llegir és barat; escriure requerix esborrat de blocs i causa WAF.
- **Arbres LSM (Log-Structured Merge-Trees):** Motors com RocksDB o Cassandra transformen escriptures aleatòries en seqüencials contínues per protegir l'SSD.
- La bretxa entre RAM i NVMe és d'1 ordre (10) de magnitud (ja no de 5 orders (100.000) com amb HDD).

# Sistemes RAID: Visió General

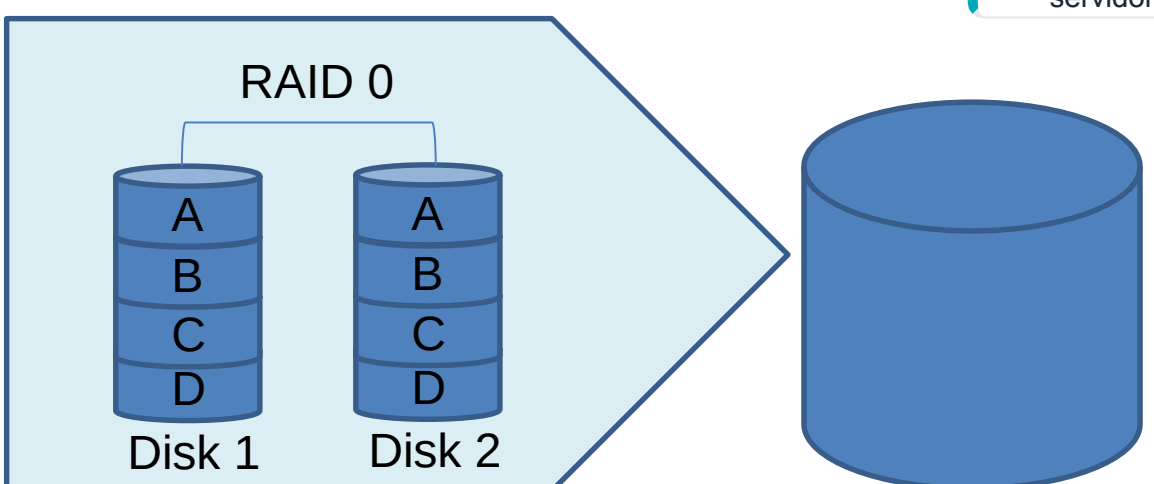
Redundant Arrays of Independent Disks

## Definició i Objectius de RAID

- Gestiona múltiples discs físics mostrant-los com un únic disc lògic de gran capacitat.
- Alta velocitat mitjançant l'ús de discs en paral·lel.
- Alta fiabilitat emmagatzemant informació de forma redundant.
- Originàriament 'Inexpensive Disks'; hui 'Independent Disks'.

## Multiplicació de Fallades

- La probabilitat de fallada creix exponencialment amb el nombre de discs.
- Si 1 disc té MTTF de 100.000 h ( aprox. 11 anys), un array de 100 discs tindrà un MTTF de només 1.000 h (aprox. 41 dies!).
- Les tècniques de redundància són imprescindibles en servidors de bases de dades.



# Millora de la Fiabilitat Mitjançant Redundància

Emmagatzematge redundant, rèplica en espill (Mirroring) i MTTDL

### Espill (Mirroring o Shadowing)

- Duplicació de cada disc físic en dos discs idèntics.
- Cada escriptura s'executa obligatòriament en ambdós discs.
- Les lectures es poden repartir entre qualsevol dels dos discs.
- Si falla un disc, les dades continuen totalment accessibles des de l'altre.

### MTTDL (Temps fins a la Pèrdua) (Mean Time To Data Loss)

- Pèrdua només si falla el disc espill abans d'haver reparat el primer.
- Probabilitat molt baixa per a fallades independents.
- Amb MTTF de 100.000 h i MTTR (Time Repair) de 10 h, el MTTDL assoleix  57.000 anys!). (Açò es veritat si el disc amb problemas es canvia per uno nou a les 10h, la probabilitat de que es trenque el segon en 10h es molt , molt baixa)

# Millora del Rendiment Mitjançant Paral·lelisme

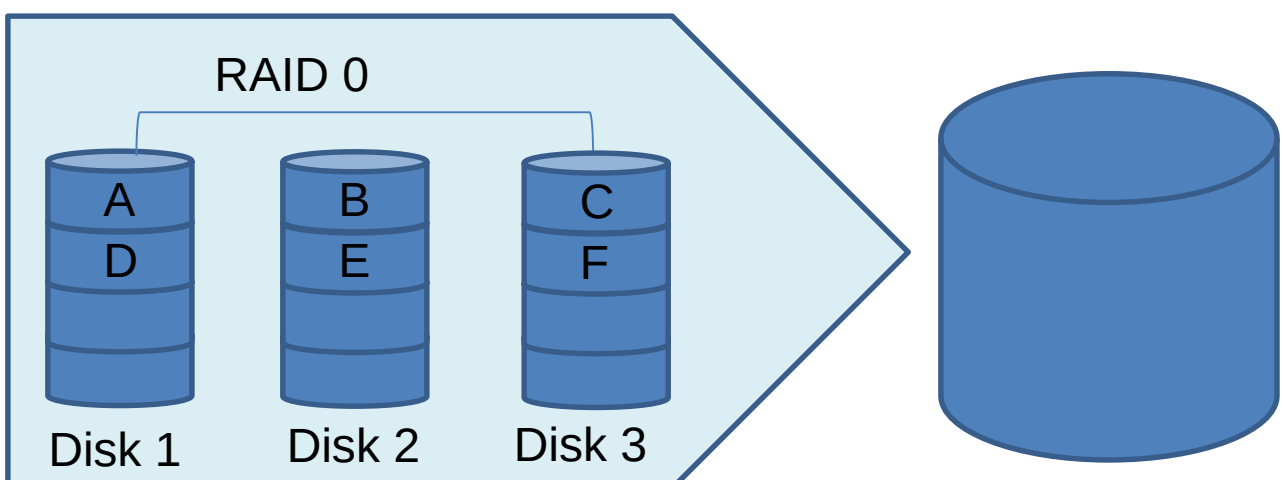
Balanç de càrrega, fragmentació de dades (Striping) a nivell de bit i de bloc

### Objectius del Paral·lelisme

- 1. Balanç de càrrega: Atendre molts accessos menuts independents simultàniament (dispara el Throughput).
- 2. Paral·lelitzar accessos grans: Reduïx el temps de resposta individual.

### Modalitats de Striping

- **Nivell de bit:** Divideix els bits de cada byte entre discs (en desús).
- **Nivell de bloc (Block Level Striping) :** Amb n discs, el bloc i s'escriu al (i mod n) +1 disc. Permet consultes simultànies sobre blocs diferents.




Block Level Striping

# Cintes Magnètiques: Formats i Rols

Formats comercials, taxes de transferència i aplicacions

## Capacitat i Formats

- Grans volums de dades i alta taxa de transferència un cop posicionat el capçal.
- Formats: DAT, DLT, Ultrium/LTO (fins a 30 TB+ per cinta).
- Taxes de transferència de desenes a centenars de MB/s.
- **Suport molt barat per gigabyte.**

## Limitacions i Casos d'Ús

- **Accés molt lent** degut a la naturalesa estrictament seqüencial.
- **Ús per a còpies de seguretat periòdiques (backups) i arxiu històric.**
- Llibreries jukebox massives que gestionen petabytes

# 2. Organització de Fitxers i Gestió de Búfers

- Organització de fitxers i registres (Fixos i variables).
- Organització en fitxers: Heap, Seqüencial i Hashing.
- Agrupament multitaula (Multitable Clustering).
- Emmagatzematge del Diccionari de Dades (Catàleg).
- Nivells d'accés a dades (SGBD → Gestor de fitxers → Gestor de disc).
- Gestió de memòria intermèdia (Buffer Manager i reemplaçament LRU).

# Organització de Fitxers

Fitxers com a seqüències de registres (Fixos vs Variables)

## Estructura Bàsica i Registres Fixos

- La BD s'emmagatzema com una col·lecció de fitxers físics.
- Cada fitxer és una seqüència de registres; cada registre, una seqüència de camps.
- **Registres Fixos (Fixed-length) (1ª Aproximació: simple):**
  - Mida de registre constant.
  - Cada fitxer conté només registres d'un tipus.
  - S'usen fitxers separats per a cada taula relacional.

## Registres de Grandària Variable

- Sorgeixen per camps alfanumèrics variables (VARCHAR, TEXT, BLOB).
- Emmagatzematge de múltiples tipus de registres en un mateix fitxer.
- Camps repetitius o col·leccions.
- Requereixen marcadors de fi o ranures internes per saber on comença i acaba cada camp.

# Organització de Registres en Fitxers

Heap (pila), seqüencial ordenat, hashing i clustering multitaula

## Mètodes d'Organització Clàssics

- **Pila (Heap):** Un registre es guarda en qualsevol bloc lliure del fitxer (inserció molt ràpida).
- **Seqüencial (Ordered):** Guardats ordenats segons la clau de cerca (òptim per a consultes per rang).
- **Hashing:** Una funció hash aplicada a cert camp determina el bloc exacte on allotjar el registre.

## Agrupació Multitaula (Clustering)

- Registres de diferents relacions s'allotgen junts al mateix bloc si tenen vincles freqüents.
- *Exemple:* Un client i totes les seues comandes al mateix bloc de disc.
- **Motivació:** Minimitzar les operacions d'E/S (I/O) en resoldre consultes amb JOIN.

# Emmagatzematge del Diccionari de Dades

Catàleg del sistema i persistència de les metadades

## Què Conté el Diccionari?

- Noms de relacions, tipus i longitud dels atributs de cada camp.
- Definicions i noms de vistes (views).
- Restriccions d'integritat (claus primàries, foranes, CHECK).
- Informació d'usuaris, rols i claus de seguretat.

## Estadístiques i Ubicació

- Dades estadístiques: nombre de tuples, factors de bloqueig (clau per a l'optimitzador).
- Organització física dels fitxers (seqüencial, hash, etc.) i posició.
- Informació sobre els índexs definits (cap. 11).
- El catàleg s'emmagatzema internament com un conjunt més de taules relacionals.

# Accés a la Informació d'una BD (Storage Access 1)

Peticions de registres, gestor de fitxers i concepte de pàgina

### Peticions de Registres des del SGBD

- El SGBD decidix el registre que necessita i el demana al **Gestor de Fitxers**.
- Per al SGBD, la BD és concebuda simplement com una col·lecció de registres emmagatzemats.
- El SGBD no interactua amb els blocs físics concrets del maquinari.

### El Gestor de Fitxers i la Pàgina

- El Gestor de Fitxers tracta els fitxers com una col·lecció de pàgines.
- **Pàgina (o bloc):** Unitat indivisible d'E/S que es transferix entre disc i RAM (4 KB a 8 KB).
- Cada pàgina té assignat un identificador únic (PageID).

# Accés a la Informació d'una BD (Storage Access 2)

Localització de pàgines i paper del Gestor de Disc

### Del Gestor de Fitxers al Disc

- El Gestor de Fitxers decidix en quina pàgina concreta està allotjat el registre i la sol·licita al Gestor de Disc.
- Sovint cal substituir o complementar el gestor de fitxers genèric del SO per garantir escriptures immediates sense caches ocultes.

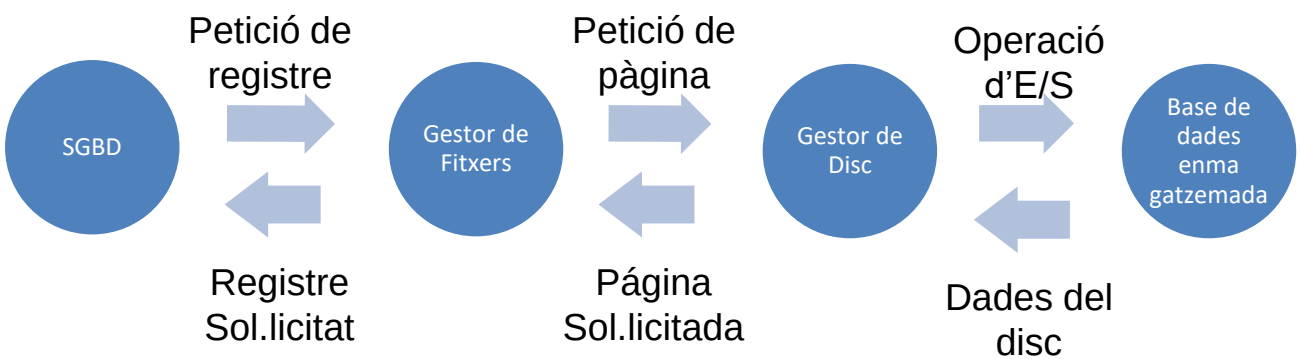
### Responsabilitats del Gestor de Disc

- Determina la ubicació física real de la pàgina en el medi (adreça LBA / cilindre-pista).
- Executa les operacions físiques d'E/S necessàries per a llegir o escriure la pàgina.

# Flux d'Accés a la Informació en la BD

Interacció entre capes: SGBD ↔ Gestor de Fitxers ↔ Gestor de Disc ↔ Disc

- **1. Petició de registre:** El SGBD sol·licita un registre lògic al Gestor de Fitxers.
- **2. Petició de pàgina:** El Gestor de Fitxers calcula en quina pàgina es troba i la demana al Gestor de Disc.
- **3. Operació d'E/S:** El Gestor de Disc tramita la lectura del bloc de disc de la base de dades emmagatzemada.
- **4. Retorn ascendent:** La pàgina es carrega a memòria, el Gestor de Fitxers extrau el registre exacte i l'entrega al SGBD.



# Accés a l'Emmagatzematge i Memòria Intermèdia

Minimització de transferències entre disc i memòria RAM

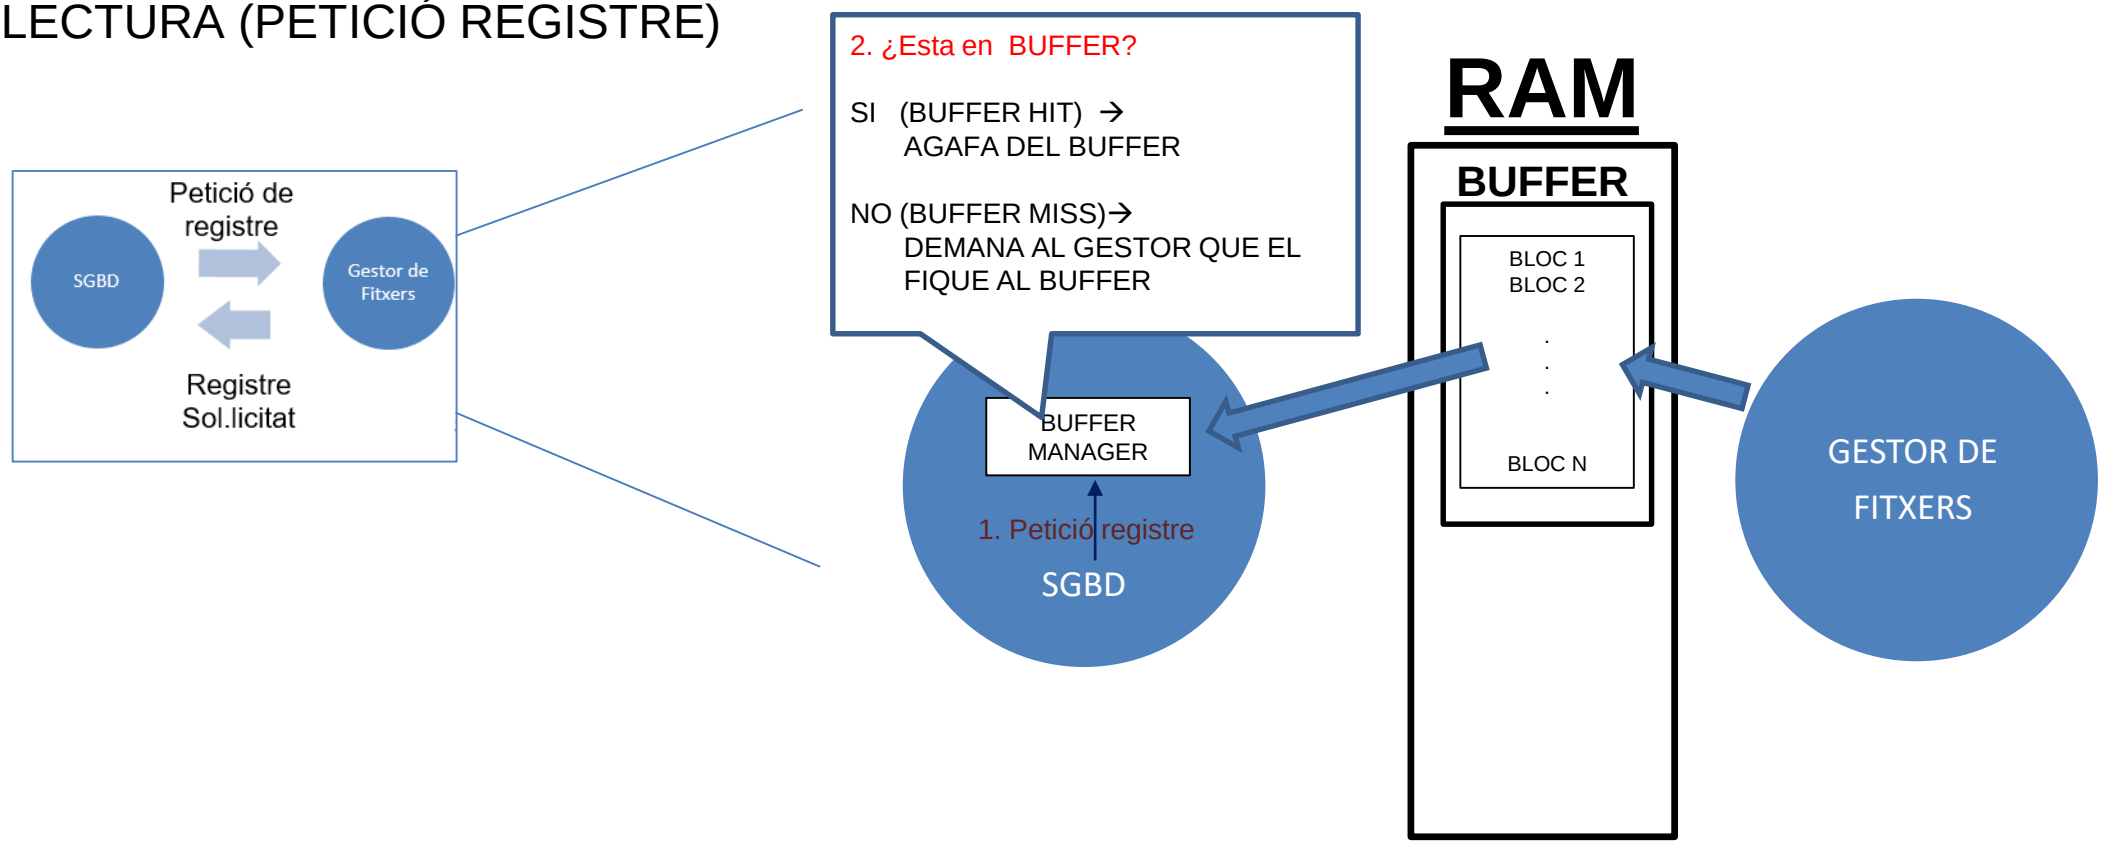
## Blocs de Fitxer i Transferència

- L'arxiu de base de dades està dividit en blocs. Els blocs són la unitat tant d'assignació d'emmagatzematge com de transferència.
- **READ:** Transferix dades de disc cap a la memòria RAM.
- **WRITE:** Transferix dades de RAM cap al disc físic.

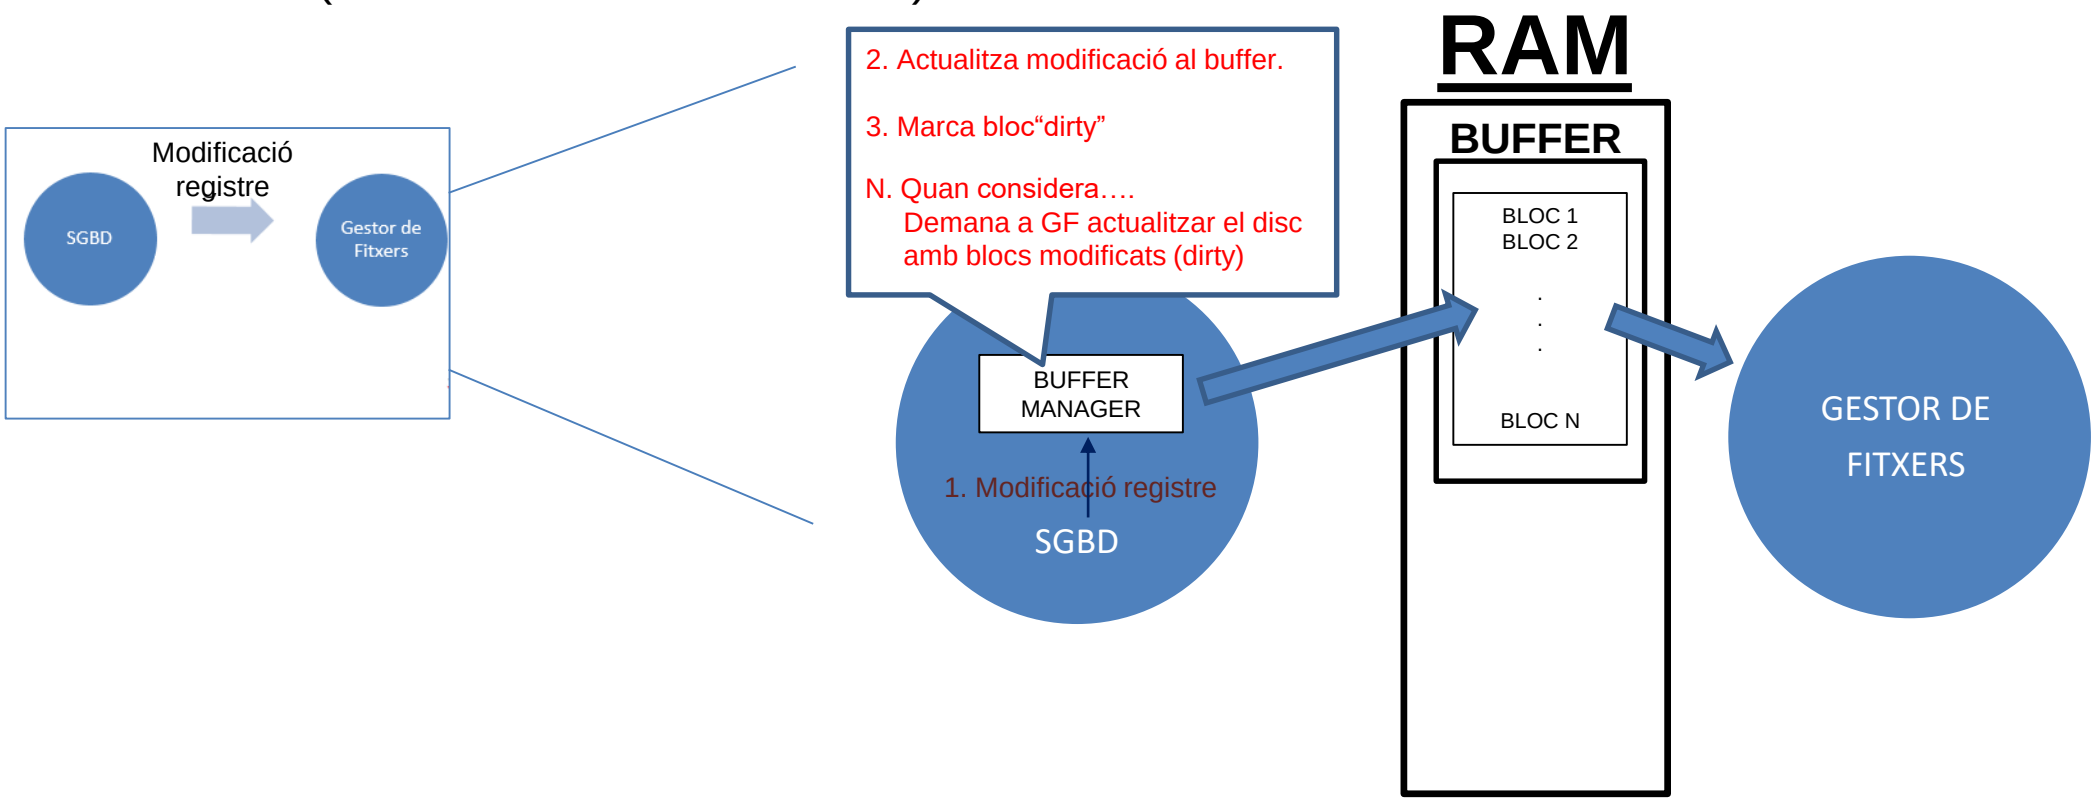
## Objectiu del SGBD i Búfers

- Minimitzar operacions d'E/S mantenint en memòria principal tants blocs com siga possible.
- **Búfer (Buffer):** Porció de RAM destinada a guardar còpies de blocs de disc.
- **Buffer Manager:** Subsistema encarregat d'assignar i administrar l'espai de búfers.

## LECTURA (PETICIÓ REGISTRE)



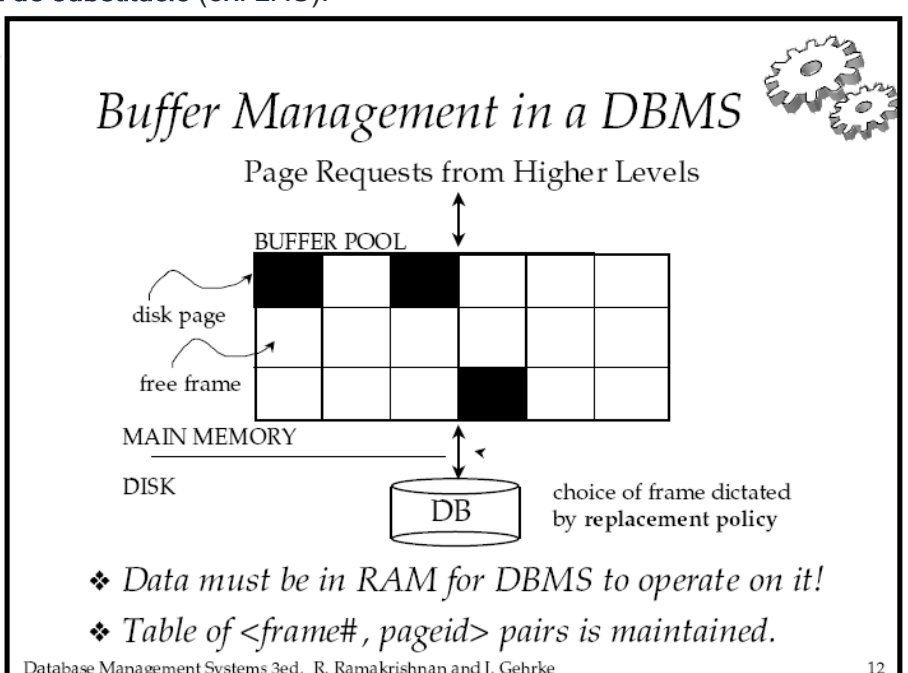
## ESCRIPTURA (MODIFICACIÓ REGISTRE)



# Gestió de la Memòria Intermèdia (Buffer Management)

Organització del Buffer Pool, marcs (frames) i correspondència amb disc

- **Requisit innegociable:** Les dades han d'estar en memòria RAM perquè el SGBD puga operar-hi directament!
- Buffer Pool dividit en **marcs (frames)** de grandària exacta a una pàgina de disc.
- Taula de marcs: El SGBD manté una taula interna amb els parells `<frame#, pageid>`.
- Marcs lliures i ocupats (amb pàgines netes o brutes).
- L'elecció del marc per **desallotjar una pàgina** ve dictada per la **política de substitució** (ex. LRU).



# Funcionament del Gestor de Búfers (Buffer Manager)

Com atén les sol·licituds: Buffer Hit vs Buffer Miss

### Buffer Hit (Ja resident)

- Si el bloc requerit ja està resident en algun marc de la memòria intermèdia:
- El Gestor de Búfers retorna directament l'adreça de memòria RAM on es troba el bloc.
- Zero operacions d'E/S a disc físic (màxima velocitat).

### Buffer Miss (No resident)

- 1. Assigna espai en el búfer per al nou bloc.
- 2. Si tots els marcs estan plens, desallotja un altre bloc seguint la política de reemplaçament.
- 3. El bloc substituït només s'escriu a disc si ha sigut modificat (**pàgina bruta o dirty**).
- 4. Llig el bloc sol·licitat des del disc al marc alliberat.

# Polítiques de Reemplaçament de Búfers

Estratègia LRU, limitacions en SGBD i blocs ancorats (Pinned Blocks)

## L'Estratègia LRU (Least Recently Used)

- Reemplaça el bloc utilitzat fa més temps (basat en el patró passat com a predictor).
- En escanejats seqüencials complets de taules grans, LRU pot expulsar pàgines útils per blocs que només es llegiran una vegada.
- Els sistemes solen usar estratègies mixtes amb pistes de l'optimitzador.

## Blocs Ancorats i Escriptura Forçada

- **Bloc ancorat (Pinned Block):** Bloc en memòria que té prohibit ser expulsat mentre s'està modificant per una transacció.
- Es manté un comptador (**Pin Count**); només s'allibera quan arriba a zero.
- **Forced Output:** Força l'escriptura immediata a disc per raons de recuperació (WAL).

# Exercici Pràctic: Gestió de Búfers (Enunciat)

Traça d'operacions concurrents d'usuaris amb una capacitat de 3 pàgines o marcs

## Seqüència d'Operacions d'Usuaris

- 1. U1: llig de la pàgina B de la BD
- 2. U1: llig de la pàgina C
- 3. U1: modifica/escriu a la pàgina C (nova versió c2)
- 4. U2: llig de la pàgina B
- 5. U1: llig de la pàgina A
- 6. U2: llig de la pàgina D
- 7. U2: modifica/escriu a la pàgina D (nova versió d2)
- 8. U3: llig de la pàgina D
- 9. U1: llig de la pàgina E
- 10. U1: escriu a la pàgina E (versió e2)
- 11. U2: llig de la pàgina F

## Estat Inicial del Sistema

**Base de Dades a disc:** A=a1, B=b1, C=c1, D=d1, E=e1, F=f1

**Espai de Búfers (3 marcs inicialment buits en RAM):**

| Marc 1 | Marc 2 | Marc 3 |
|---|---|---|
| [ buit ] | [ buit ] | [ buit ] |

Usuaris actius: U1, U2 i U3 concurrentment.

# Exercici Pràctic: Resolució de la Traça dels Búfers

Evolució pas a pas dels marcs de memòria i escriptura de pàgines brutes (*) a disc

| Pas | Marc 1 | Marc 2 | Marc 3 | Acció / Observació LRU |
|---|---|---|---|---|
| 1. U1 llig B | 1: B=b1 | 2: - | 3: - | Carrega B a Marc 1 |
| 2. U1 llig C | 1: B=b1 | 2: C=c1 | 3: - | Carrega C a Marc 2 |
| 3. U1 mod C (c2) | 1: B=b1 | **2: C=c2 *** | 3: - | Marca C com a bruta (*) |
| 4. U2 llig B | 1: B=b1 | 2: C=c2 * | 3: - | Hit de B (s'actualitza LRU de B) |
| 5. U1 llig A | 1: B=b1 | 2: C=c2 * | 3: A=a1 | Carrega A a Marc 3 (Búfer ple) |
| 6. U2 llig D | 1: D=d1 | 2: C=c2 * | 3: A=a1 | Expulsa B (menys usat). B era neta, no s'escriu a disc |
| 7. U2 mod D (d2) | **1: D=d2 *** | 2: C=c2 * | 3: A=a1 | Modifica D en RAM (bruta *) |
| 8. U3 llig D | 1: D=d2 * | 2: C=c2 * | 3: A=a1 | Hit de D (s'actualitza LRU de D) |
| 9. U1 llig E | 1: D=d2 * | 2: C=c2 * | 3: E=e1 | Expulsa A (LRU). Carrega E |
| 10. U1 escriu E (e2) | 1: D=d2 * | 2: C=c2 * | **3: E=e2 *** | Modifica E en RAM (bruta *) |
| **11. U2 llig F** | 1: D=d2 * | **2: F=f1** | 3: E=e2 * | **Expulsa C! Com que C era bruta (*), S'ESCRIU C=c2 A DISC!** |