Departamento de Informática, Univ. de Valencia

Sistemas Inteligentes

Juan Domingo
Juan.Domingo@uv.es

Septiembre de 2026

Tema 1:

Introducción y agentes

Índice del tema 1: comienzo de la sección 1

1 Introducción a la IA
1.1 Definiciones
1.2 Agentes
1.3 Aproximaciones a la IA
1.4 Subdisciplinas de la IA
1.5 Evolución histórica

2 Agentes
2.1 Definiciones
2.2 Arquitecturas de agentes
2.3 Arquitecturas multiagente
2.4 Vida artificial (AL)

Definiciones de la Inteligencia Artificial (AI)

Definición emulativa

AI es la técnica que consiste en conseguir que una máquina haga algo que, de ser hecho por un humano, diríamos que requiere inteligencia. (Kurzweil, 1990)

Definición operativa

La rama de las ciencias de la computación que estudia la automatización del comportamiento inteligente. (Luger, 1988).

Definición general (la más ambiciosa)

Es la ciencia que estudia el fenómeno de la inteligencia, y la posibilidad de reproducirlo, total o parcialmente, por medios artificiales. (Minsky, 1958).

Agentes inteligentes

Un **agente inteligente** es...

Definición débil

Una entidad que se comporta de modo similar, o incluso mejor en términos de resultados, que un humano enfrentado a un problema intelectual complejo.

Definición agnóstica

Igual que la definición anterior, pero además la entidad usa un método correcto (es decir: comprensible y explicable) para la resolución del problema.

Definición fuerte

Igual que la definición anterior, pero además la entidad tiene la experiencia consciente de ello (es decir, es consciente de que sabe, y de que ha resuelto o no el problema).

Patrones y conceptos (I)

Para describir un grupo de objetos, o en general de entidades, se usan características (a ser posible, cuantificables) asociadas a ellos (ej.: la forma, el color, las dimensiones, la intensidad..)
Para entender la diferencia entre las definiciones anteriores de IA es necesario distinguir entre:

Patrón:

Un grupo de entidades que comparten valores similares de varias de sus características relevantes.

Las únicas propiedades de un patrón son los propios valores de las características.

Concepto:

La representación intelectual de un grupo de entidades.

Las propiedades de los conceptos son la comprensión y la extensión: la primera denota las características esenciales que contiene el concepto, y la segunda el número (cantidad de sujetos) a los que puede aplicarse.

Patrones y conceptos (II)

Los patrones pueden ser aprehendidos por ordenadores de modo simple. Los conceptos requiren representaciones complejas y deberían poder comunicarse sin necesidad de que el agente receptor haya percibido antes ningún ejemplo de ninguna entidad constituyente.

Tanto los patrones como los conceptos son ambigüos. La ambigüedad en patrones se limita con rangos para las características usadas. En conceptos, añadiendo notas distrintivas que reduzcan la extensión.

Ejemplos existentes de agentes inteligentes

Agente que sigue la definición débil

Todos los basados en reconocimento de patrones, como...

- Sistemas para recomendación o sugerencia (de compras, música, etc.).
- Sistemas de diagnóstico médico que comparan síntomas y valores con los de sujetos sanos y enfermos.

Agente que sigue la definición agnóstica

Todos los capaces de detallar (diríamos, "explicar") el proceso por el que obtienen un resultado, como...

- Sistemas expertos (hechos y reglas de razonamiento)
- Antiguos programas de ajedrez

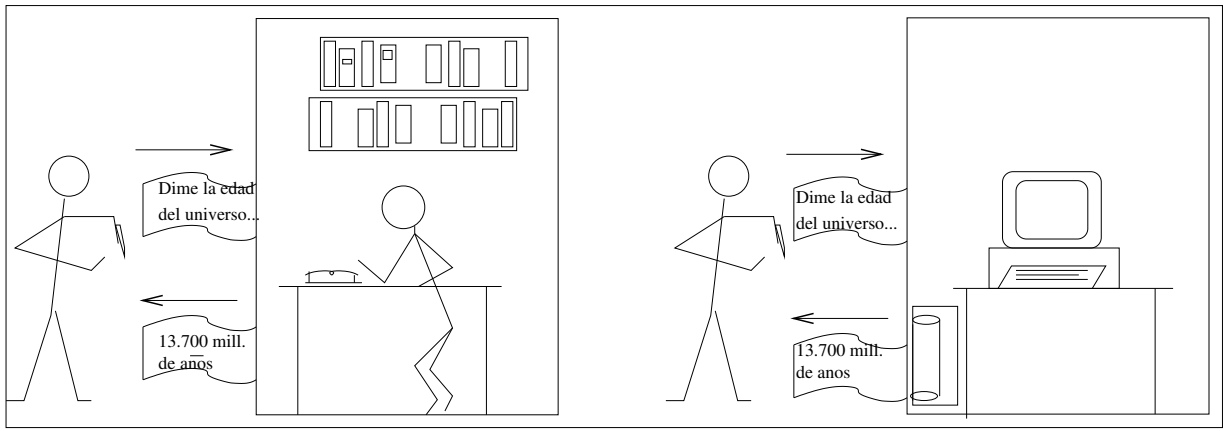
Agente que sigue la definición fuerte

No existen ejemplos (¿aún?)

AI general

La **AI débil** ("soft AI") trata de crear programas o dispositivos que se comportan inteligentemente en ámbitos restringidos (p. ej.: coches autónomos).
Por contra, el objetivo declarado de la **AI fuerte** ("hard"o "strong"AI) es crear artificialmente entidades que exhiban inteligencia general, en el sentido humano del término, pero ¿cómo sabríamos que la tienen?

Test de Turing

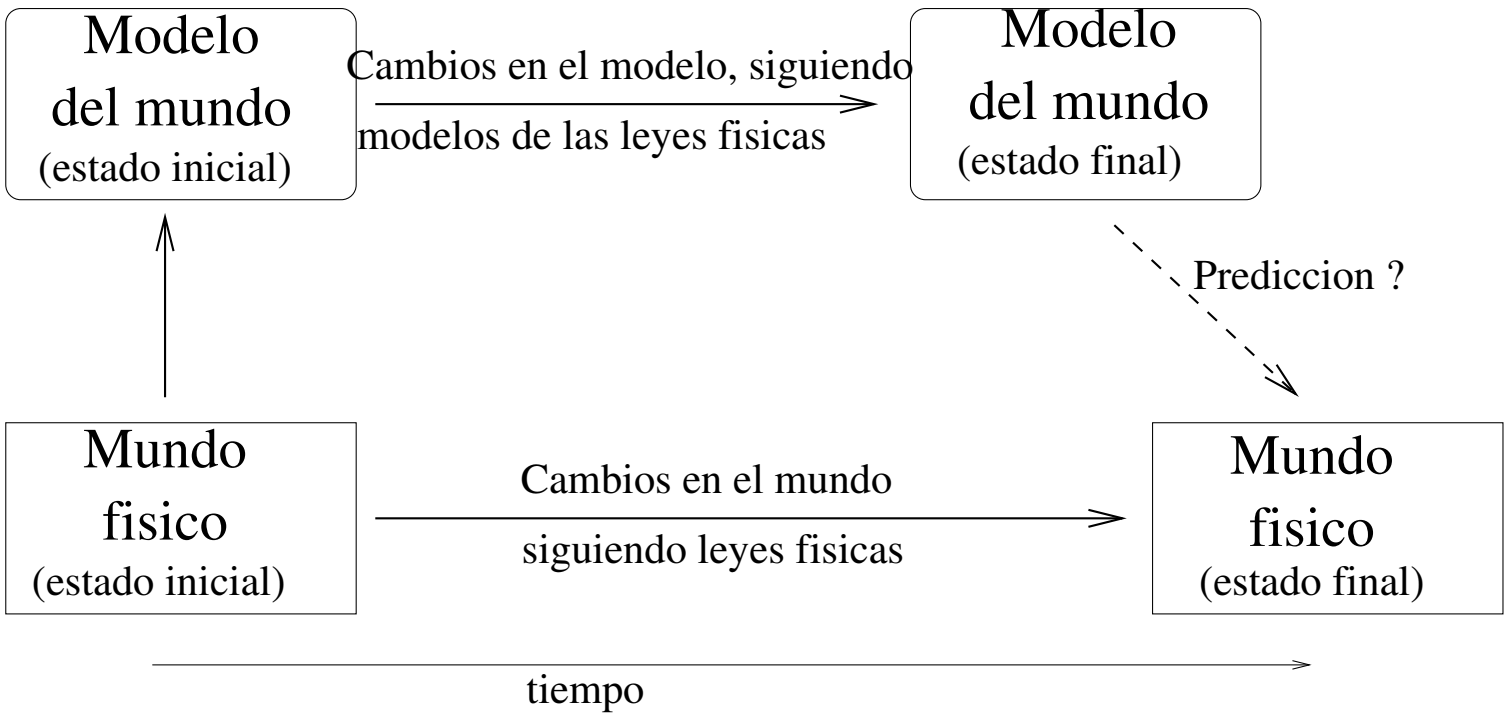


Un interrogador que puede comunicarse sólo por escrito debe averiguar si en el interior de la habitación hay un humano o un ordenador.

Hipótesis de Newell y Simon

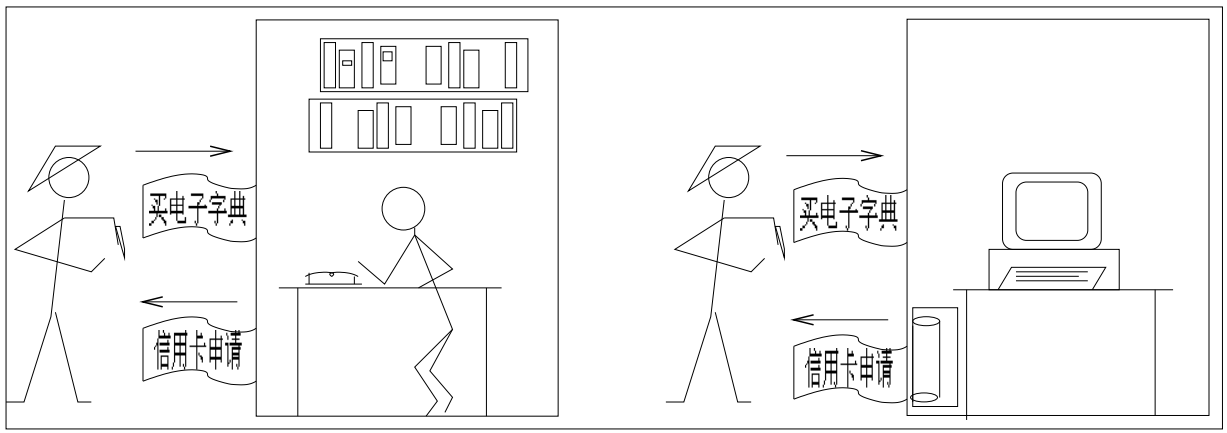
Hipótesis del Sistema Físico de Símbolos (PSSH) (Newell y Simon, 1976):

> *"Un sistema físico de símbolos posee los medios necesarios y suficientes para producir acción inteligente general"*



El contraargumento de Searle

La manipulación de símbolos usando reglas **no** puede ser suficiente. Como ejemplo, imaginemos que hacemos pasar el test de Turing en chino usando como persona a alguien, digamos Searle, que no sepa chino...



Searle opera como un ordenador, y preguntado después si ha entendido algo, diría honestamente que no. Por tanto, tampoco el ordenador.
¿Qué falta? La capacidad de los símbolos de apuntar al mundo real (intencionalidad).

Funcionalismo simbólico y robótico

Funcionalismo simbólico:

La tendencia que asume que la hipótesis del sistema físico de símbolos es correcta y suficiente para generar acción inteligente general.

La mayoría de las aplicaciones actuales la siguen: los datos se introducen directamente como símbolos (cadenas binarias) y se procesan. Hay actualmente una gran intersección con la ciencia de datos.

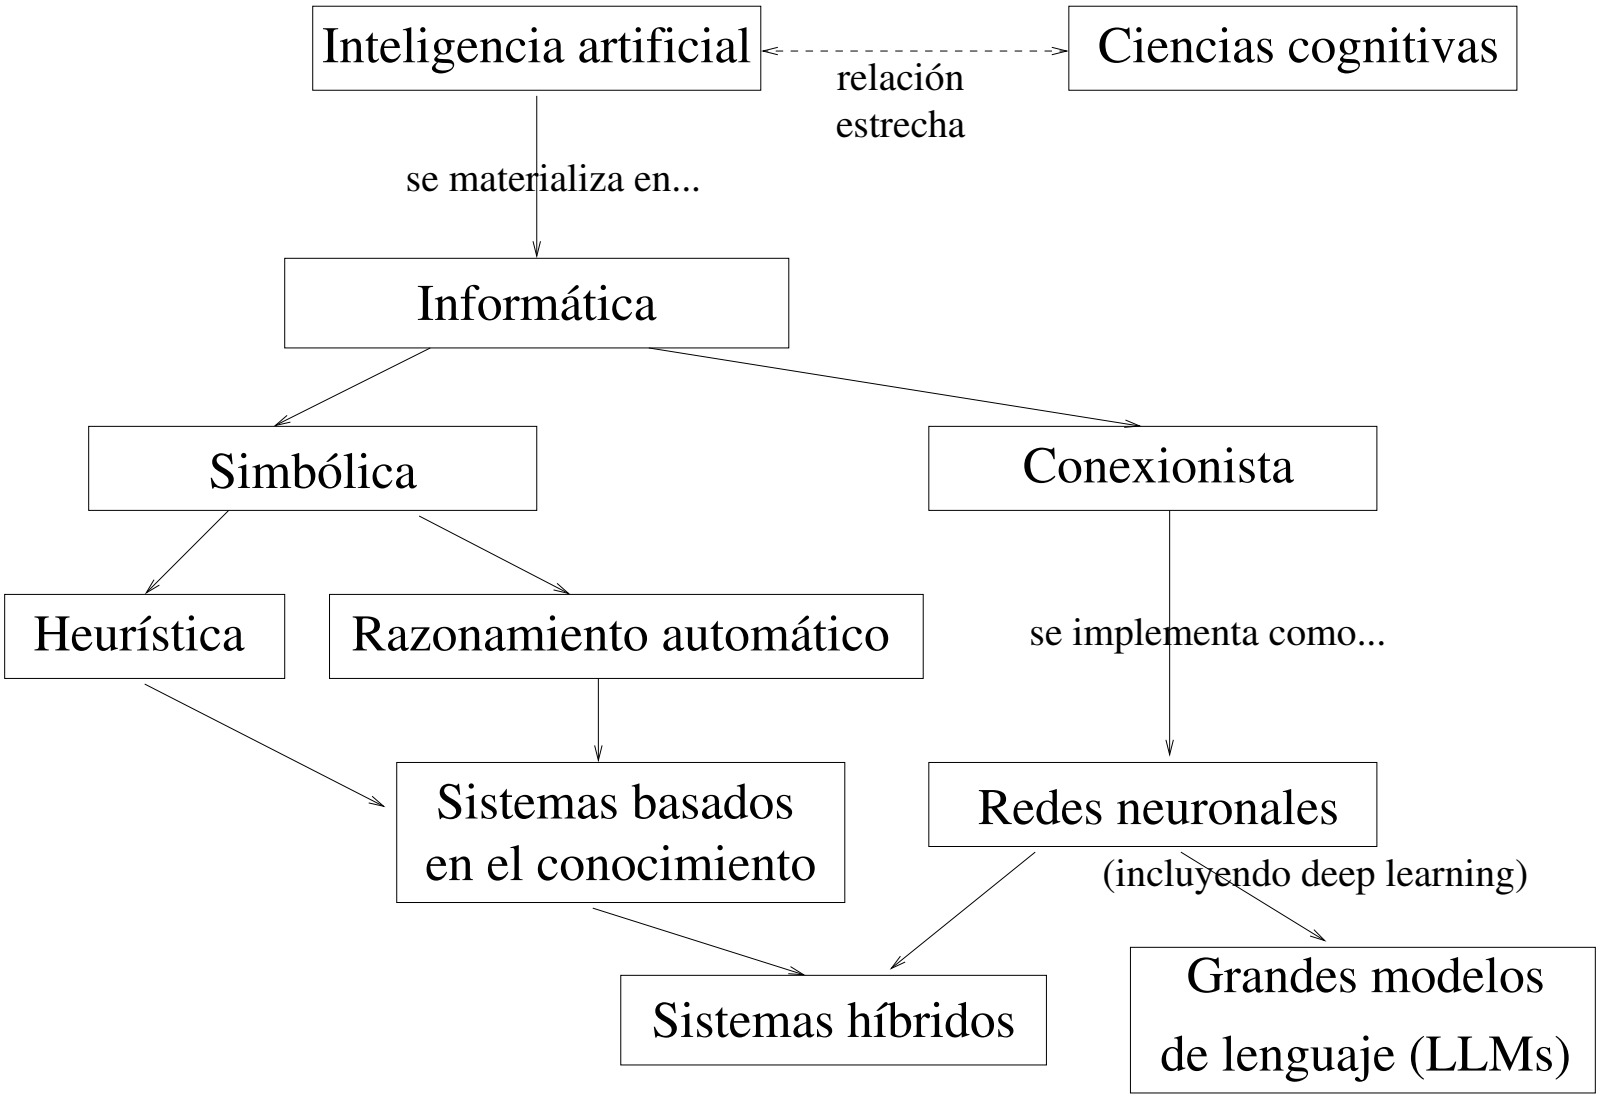
Funcionalismo robótico:

La tendencia que impone la necesidad de conectar a la entidad inteligente con el mundo real mediante **sensores** y **actuadores**, lo que implica dotarla de un **sistema de percepción**.

Aquí entran los robots, vehículos autónomos, etc.

Aun así, ninguna de las dos tendencias resuelve el problema de la **autoconciencia** (la entidad **sabe que sabe** y es capaz de razonar acerca de sus propios razonamientos).

Subdisciplinas de la IA



Evolución histórica de la IA (I)

Los inicios (1943-1956)

- Neurona artifical de McCulloch y Pitts: un modelo simplificado que, sin embargo, permite construir un modelo de computación completo, y tiene cierta capacidad de aprendizaje (regla de Hebb, 1949)
- Programas de ajedrez (Shannon, 1950; Turin, 1953) para ordenadores con arquitectura Turing/von Neumann
- Conferencia de Darmouth (1956): McCarthy acuña el término Inteligencia Artifical. Se presentan programas para juegos y razonamiento lógico (Logic Theorist, Newell y Simon).

Evolución histórica de la IA (II)

Primera etapa (1956-1970)

- Se comienzan a fijar los modos de representación de problemas complejos, especialmente los espacios de estados.
- Se advierte la diferencia entre procedimientos **algorítmicos** y **heurísticos**

  Algoritmos: son válidos para problemas cuya formulación contiene toda la información necesaria para resolverlos.

  Heurísticas: se añade conocimiento extra, no consustancial a la estructura del problema, que guía la búsqueda de soluciones.
- Se recurre a la formalización del razonamiento lógico para resolver (aun cuando la lógica de primer orden no tiene procedimiento general de resolución).
- Se generan nuevos formalismos de representación, como las redes semánticas (Quillian, 1963).
- Se avanza en redes neuronales (McCulloch y Pitts, modelo de una neurona artificial) y Rosenblatt (el perceptrón).
- Se diseña e implementa el primer lenguaje de programación específico para la AI: LISP (McCarthy).

Evolución histórica de la IA (III)

Etapa de prototipos (1971-1981)

Se rebajan las expectativas iniciales, debido a la dificultad de escalar modelos "de juguete" a problemas reales. Aun así, aparecen:

- Planificadores de acciones (para robots u otros): STRIPS, NOAH.
- Analizadores de lenguaje natural: LADDER, SHRDLU.
- Sistemas expertos: MYCIN, PROSPECTOR y otros. El principal logro comercial.
- Lenguajes para programación lógica, en particular, PROLOG (Colmenauer y Kowalski, 1975).

Evolución histórica de la IA (IV)

Etapa de difusión industrial (1982-1988)

Se intentan aprovechar los sistemas expertos para usarlos en problemas reales de gran complejidad.

- Implementación del sistema R1 en DEC para la configuración de sistemas informáticos.
- Proyecto de 5ª generación en Japón usando PROLOG.
- Creación de entornos ("shells") para la programación de sistemas expertos.

El éxito es relativo; la conclusión es que el éxito de un sistema experto es inversamente proporcional a la extensión del dominio de conocimiento para el que resulta útil. La falta de sentido común (imposibilidad de autovalidación de las reglas, o de generación automática de reglas incluso muy obvias) limita la eficacia.

Evolución histórica de la IA (V)

Retorno de la computación conexionista (1988-..)

- Conexiones con la mecánica estadística (Hopfield, 1982).
- "Redescubrimiento" del algortimo de retropropagación (backpropagation) (Rumelhart, 1986)
- Otros modelos de redes (p. ej. red autoorganizativa, Kohonen, 1990)

Evolución histórica de la IA (VI)

Agentes situados (robots, etc.) (1986-..)

La competición de dos visiones de la robótica, la clásica, que se inspira en la PSSH, y la comportamental, basada en la implementación de reflejos y comportamientos simples, dan lugar a nuevas arquitecturas para el control de la percepción. Son ejemplos:

- Sistema clásico de percepción y planificación de tareas robóticas: HANDEY (Lozano-Perez, 1987)
- Sistemas comportamentales para obtener resultados sin programación explícita: Herbert (Connel, 1989).
- Arquitecturas híbridas que conectan el razonamiento de alto nivel y la acción de bajo nivel (Arkin, 1990).

Evolución histórica de la IA (VII)

Logros actuales

No existe evidencia de la consecución de la IA dura (inteligencia general) (opinión personal).
Sin embargo, hay extraordinarios logros concretos en áreas específicas, sobre todo por el entrenamiento basado en la recolección y análisis de cantidades enormes de datos (big data), p. ej.:

- Reconocimento del habla, usando modelos ocultos de Markov.
- Reconocimento de caracteres.
- Sistemas de recomendación.
- Traducción automática entre idiomas.
- Generación automática de código en lenguajes de programación.
- Análisis de imágenes y reconocimento de objetos.
- Robots semiautónomos y sistemas de conducción autónoma.

Y sobre todo: sistemas de búsqueda y recombinación con interfaz E/S en lenguaje natural, los **modelos grandes de lenguaje**, LLMs.

Índice del tema 1: comienzo de la sección 2

1 Introducción a la IA
1.1 Definiciones
1.2 Agentes
1.3 Aproximaciones a la IA
1.4 Subdisciplinas de la IA
1.5 Evolución histórica

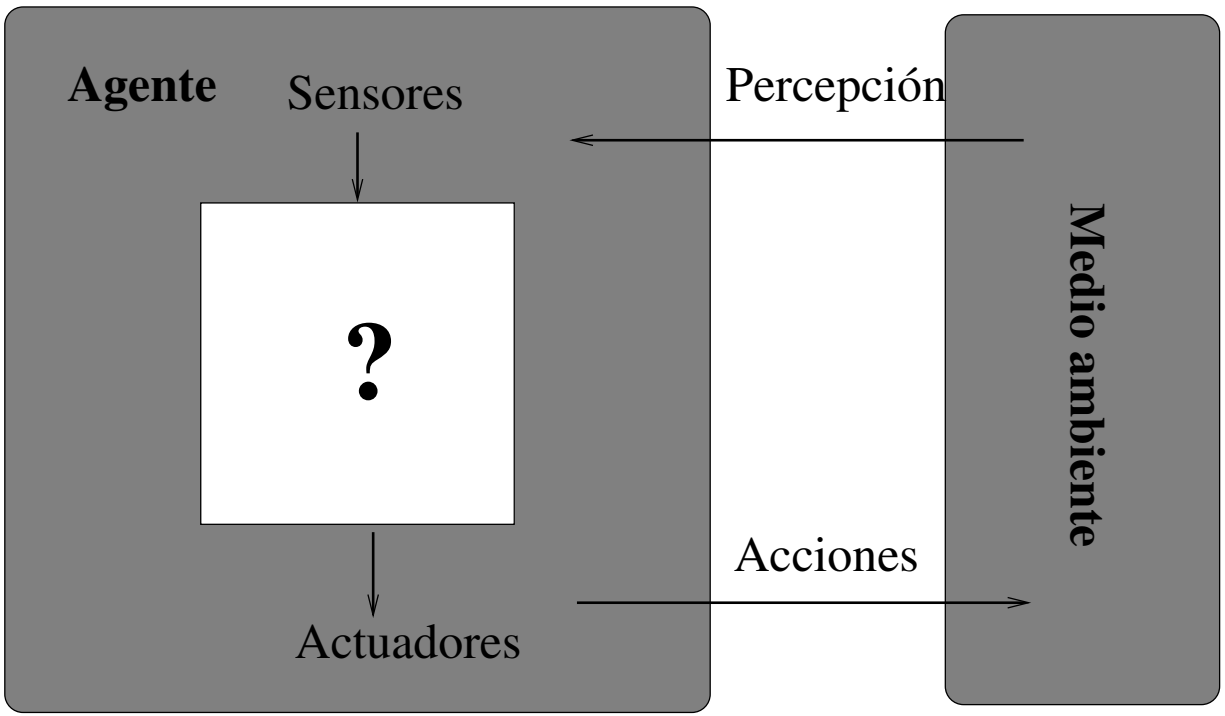
2 Agentes
2.1 Definiciones
2.2 Arquitecturas de agentes
2.3 Arquitecturas multiagente
2.4 Vida artificial (AL)

Agente

Agente:

Cualquier entidad capaz de percibir su medioambiente con la ayuda de sensores y de cambiar ese medio utilizando actuadores (Russell, 2005).

Ejemplos: Cualquier animal, incluso los más elementales (bacterias,..). Los humanos. Robots con cámaras, telémetros y motores.



Percepción, comportamiento y programa

Percepción:

Proceso por el que una secuencia temporal de señales de los sensores son captadas y procesadas por el agente. En ciertos (muchos) agentes se puede asumir que las acciones anteriores son recordadas (se han almacenado en una memoria interna accesible al agente).

Comportamiento:

Proceso por el que una función interna al agente toma como entrada la percepción (señales pasadas y presentes) y genera una o más acciones (órdenes para los actuadores). La función del agente puede verse como una tabla, muchas veces muy grande, incluso infinita.

Programa:

La implementación en un agente de la función de comportamiento.

Ejemplo

El sistema de control de tráfico aéreo de Ruritania falla de repente, debido a terribles condiciones meteorológicas. Afortunadamente, los sistemas de control computerizados de los países vecinos negocian entre ellos para monitorizar y gestionar cada vuelo afectado, y la situación potencialmente desastrosa pasa sin mayores complicaciones.

La solución automática de este escenario es irreal actualmente, aunque existan sistemas de ayuda y soporte computerizado al control de tráfico aéreo. Muestra, sin embargo, un entorno complejísimo con casi todas las características de un problema que necesitará técnicas de IA.

Escenarios en AI

A diferencia del entorno relativamente simple en que opera un programa secuencial individual (la memoria de un ordenador), un agente en AI...

- Está en un entorno en constante cambio.
- Tiene sólo conocimiento parcial, y posiblemente incorrecto, del ambiente.
- Cuando actúa tiene un control sólo parcial sobre el resultado de sus acciones.
- Puede tener tareas que entren en conflicto entre sí (al menos, con la visión instantánea del ambiente).
- Suele tener a su disposición varios cursos de acción permitidos.
- Debe dar una respuesta en tiempo acotado, y quizá muy breve.

Propiedades de un agente (I)

Propiedades imprescindibles:

- Autonomía: debe operar sin la intervención directa de humanos, y debe tener cierto control sobre sus acciones y su estado interno.
- Habilidad social: debe poder cooperar con humanos o con otros agentes.
- Reactividad: debe percibir su entorno, y reaccionar en tiempo razonable a los cambios en él.
- Proactividad: además de actuar en respuesta al entorno, el agente debe exhibir comportamiento guiado por objetivos tomando la iniciativa.

Propiedades de un agente (II)

Propiedades deseables:

- Movilidad: capacidad de "desplazarse" (en un entorno físico, virtual, o en la red).
- Veracidad: se asume que el agente no comunicará información falsa a sabiendas (no existe ninguna parte del programa que cambiará la información recogida o deducida antes de enviarla a otro agente). Eso no implica necesariamente que la información comunicada sea cierta, en el sentido de acorde al mundo real.
- Benevolencia: si existen varios agentes, los objetivos serán comunes, y cada agente intentará cumplir las órdenes que se le den.
- Racionalidad: un agente actuará para cumplir sus metas programadas, y no actuará para impedir se cumplan.
- Aprendizaje: un agente podrá modificar su comportamiento para adaptarlo a un entorno cambiante.

Rendimiento y racionalidad

Medida de rendimiento:

Una función cuya entrada es el estado del entorno del agente y cuya salida es un número, tanto mayor cuanto más se parezca ese estado al estado deseado por el programador.

Definida así, la medida de rendimiento es subjetiva, y debe programarse explícitamente, aunque veremos que es posible que el agente la aprenda, maximizando criterios más generales (como la propia supervivencia del agente, o de otros agentes, o la información recibida de éstos).

Racionalidad:

Grado de ajuste del agente a cuatro criterios:

- La medida de rendimiento.
- El conocimiento del medio ambiente prealmacenado.
- La variedad del repertorio de acciones posibles.
- La secuencia de percepciones hasta el momento.

Agente racional

Agente racional:

Aquel que ante cada posible secuencia de percepciones, emprenda aquella acción que supuestamente maximice su medida de rendimiento, basándose en dos cosas:

- Las evidencias aportadas por la secuencia de percepciones
- El conocimiento que el agente mantiene almacenado, tanto del entorno como de sus acciones previas, y de los resultados de éstas.

El conocimiento de cuáles han sido las acciones anteriores generalmente se asume. Sin embargo, el conocimiento de sus consecuencias no siempre es accesible. Sin embargo, si deseamos **no** programar explícitamente la medida de rendimiento, entonces sí debería serlo.

Entorno

Entorno:

Es el problema al que el agente busca soluciones. Se compone de:

- La medida de rendimiento.
- El medio ambiente.
- Los sensores.
- Los actuadores.

Ejemplo: un sistema de diagnóstico médico

- Medida: la cantidad de pacientes curados y el coste de los tratamientos.
- Medio: los pacientes y el hospital.
- Sensores: los síntomas que se perciben, las respuestas de los pacientes a las preguntas del médico, los resultados de las pruebas diagnósticas (análisis, pruebas de imagen)
- Actuadores: las preguntas a los pacientes, los instrumentos y procesos de las pruebas.

Clasificaciones para los entornos (I)

Totalmente observable o parcialmente observable

En el primero se sensoriza el estado actual completo (ej.: ajedrez). En el segundo hay variables relevantes para el estado fuera del alcance de los sensores (ej.: póker).

Determinista o aleatorio (estocástico)

En el primero el siguiente estado viene totalmente determinado por el estado actual y por la acción del agente (ej.: damas). En el segundo actúa algún elemento externo de carácter impredecible (ej.: parchís).

Episódico o secuencial

En los primeros el entorno se configura como una sucesión de episodios atómicos y la elección de la acción depende sólo de la percepción actual (de este episodio). (ej.: tres en raya). En los segundos la elección depende de la historia anterior, y por tanto condiciona la evolución futura; en estos casos el agente debe tener algún tipo de memoria. (ej.: laberinto).

Clasificaciones para los entornos (II)

Estático o dinámico

En el segundo el entorno puede cambiar mientras el agente está decidiendo su acción (deliberando). (ej.: un sistema de ensamblado robótico). En el primero se garantiza que el entorno no cambia hasta que el agente realice sobre él su acción. (ej.: go)

Discreto o contínuo

En los primeros el número de estados posibles (configuraciones diferentes que puden ser percibidas) es finito (aunque quizá muy grande) (ej.: damas). En los segundos los sensores miden variables contínuas y hay por tanto infinitos estados (ej.: coche autónomo).

Clasificaciones para los entornos (III)

De agente individual o multiagente

En los primeros actúa sólo un agente (ej.: sudoku) y en los segundos, dos o más (ej.: juegos de equipo). Puede haber duda sobre si cierta entidad del entorno es agente u objeto. Si el comportamiento de la entidad se describe maximixando una función que no depende de él mismo, sino de otro objeto, ése otro es un agente, no él (ej.: objeto taxi, que depende del agente taxista).
En entornos multiagente puede darse **cooperación** (la medida de rendimiento es una y la misma para todos los agentes) o **competición** (cada agente trata de maximizar su medida de rendimiento, incluso a costa de minimizar la del otro/otros). Si se da cooperación, la **comunicación** entre agentes emerge como comportamiento racional.

Todas estas clasificaciones son independientes, es decir, cada entorno será una de las dos cosas para cada clasificación, independientemente de las otras.

Definición de arquitectura

Arquitectura:

División de un sistema destinado a realizar cierta tarea en partes discernibles, que se conectan entre sí mediante relaciones igualmente discernibles.

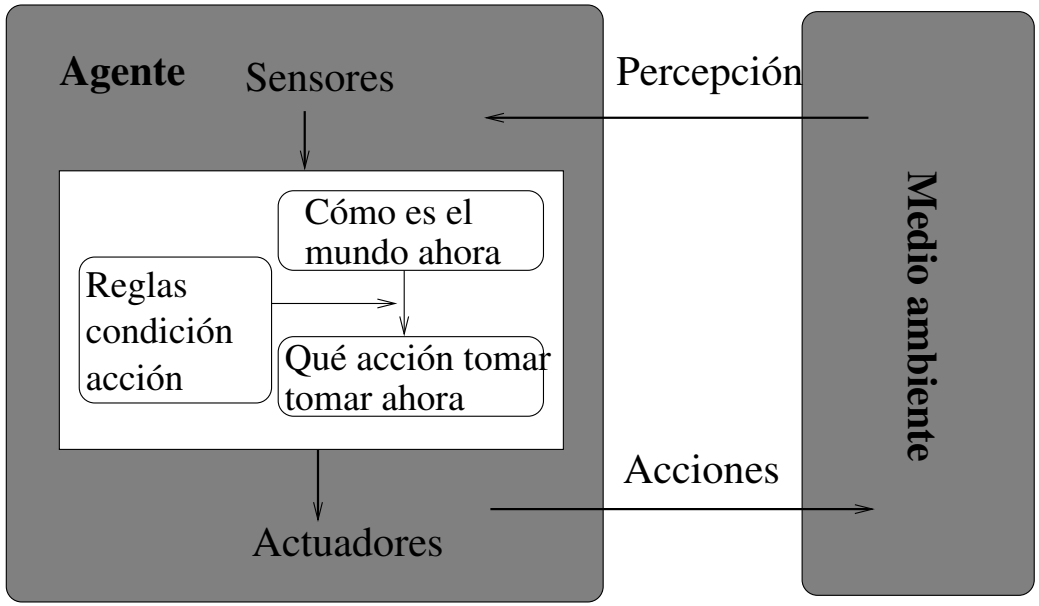
Alternativamente:

> *"El diseño abstracto de una clase de agentes: el conjunto de componentes estructurales sobre el cual ocurren la percepción, el razonamiento y la acción; la función específica y el interface de cada componente, y la topología de interconexión entre componentes"*
>
> *(Hayes-Roth, 1995)*

Deberemos escoger:

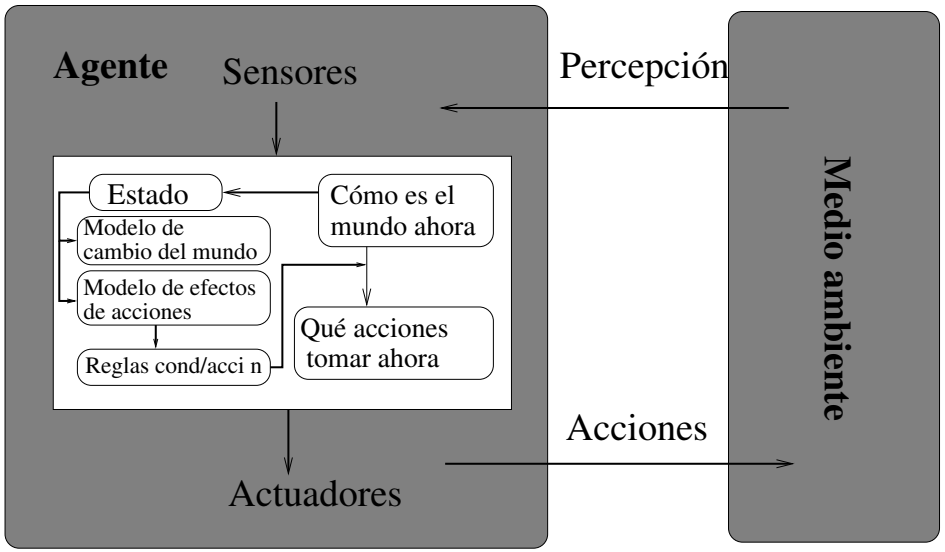
- Los bloques básicos (hardware, software, entorno,...)
- Las relaciones entre ellos (explícitas, implícitas, mediadas por el entorno,...)
- La topología de conexión.

Clas. A: Agentes reactivos simples



Su medio de razonamiento es una tabla que asocia percepciones sensoriales que se repiten habitualmente con las acciones que cada una debe desencadenar (modelo estímulo/respuesta).
Sólo son eficaces en entornos muy simples y con un número bastante limitado de estados.

Clas. A: Ag. reac. basados en modelos

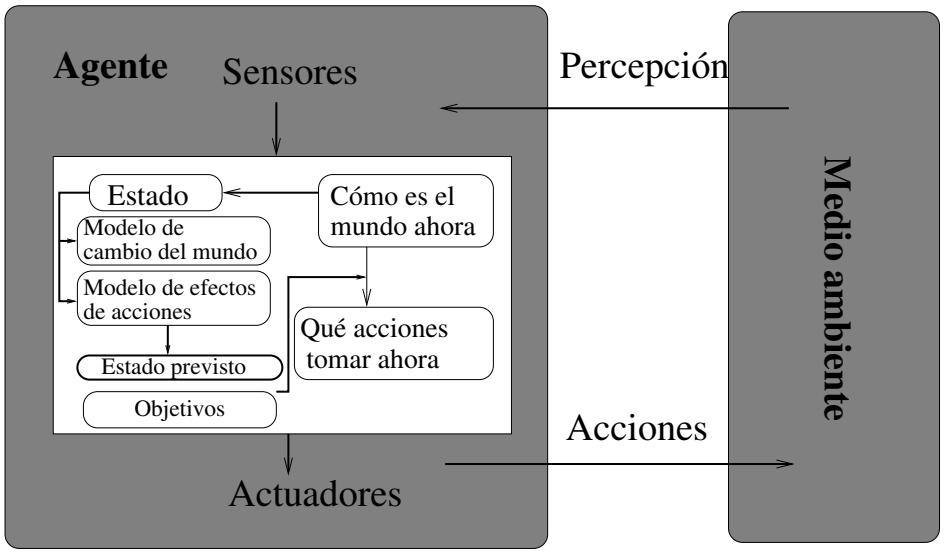


Aquí el agente determina a partir de los sensores cuál es el estado actual del medio, y tiene un modelo que...

- Sabe qué acciones son aplicables en ese estado
- Predice a qué estado se evolucionaría suponiendo que se aplicara cada una de las posibles acciones

De acuerdo a ello, escoge la acción que lleve al mejor estado (de acuerdo con la medida de rendimiento escogida).

Clas. A: Agentes basados en objetivos

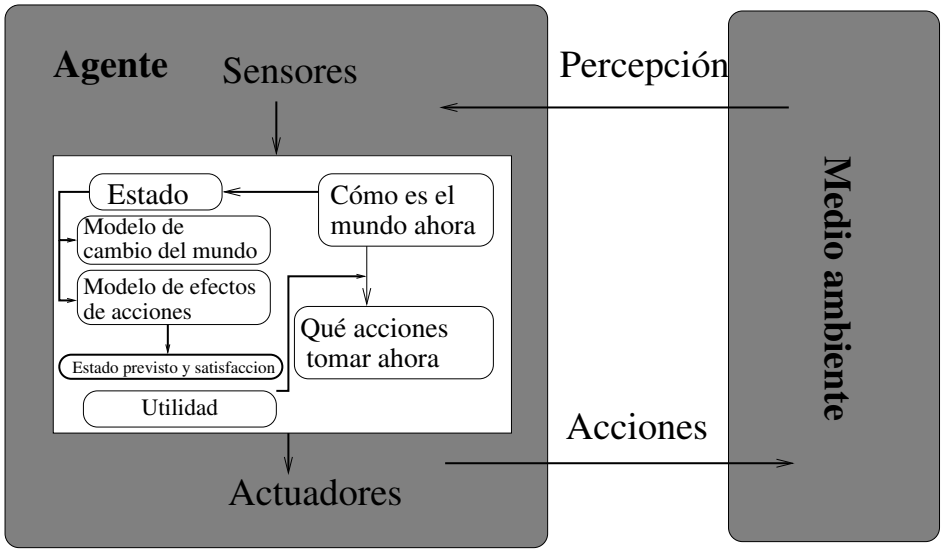


Es prácticamente idéntico al caso anterior, pero las reglas de asociación simple son sustituídas por un razonador con objetivos que conoce el objetivo final.

El resultado es que, a diferencia del anterior, aquí es posible que ante un mismo ambiente y estado, la acción escogida sea diferente, si es que hubiera cambiado el objetivo final.

De hecho, la medida de rendimiento en este caso suele ser la inversa de la similitud entre el estado actual y el estado objetivo.

Clas. A: Agentes basados en la utilidad

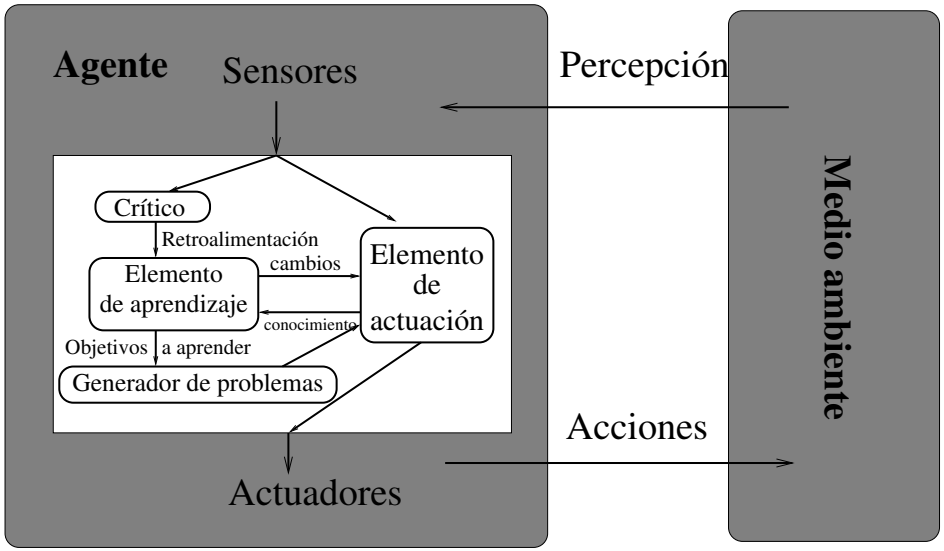


Muy similar al caso anterior, pero además de considerar sólo los objetivos se considera, de entre todas las posibles formas de alcanzarlos, cuál es más confortable o beneficiosa para el agente.

En caso de haber varios objetivos, y no pder alcanzarlos todos, se alcanzará el más útil. En este caso la arquitectura anterior se pararía.

La medida de rendimiento tiene en cuenta la inversa de la similitud entre el estado actual y el estado objetivo, así como la satisfacción del agente con cada estado.

Clas. A: Agentes que aprenden



Un agente que aprende se puede dividir en cuatro componentes:

- Elemento de actuación: se responsabiliza de acciones externas. Recibe estímulos y determina las acciones a realizar.
- Elemento de crítica: critica la actuación del agente y transmite esta crítica sobre el elemento de aprendizaje.
- Elemento de aprendizaje: es el encargado de hacer mejoras sobre el elemento de actuación, basándose en las críticas que sobre él ha recibido.
- Generador de problemas: es responsable de sugerir acciones que lo guiarán hacia experiencias nuevas e informativas.

Clas. B: Arquitecturas deliberativas

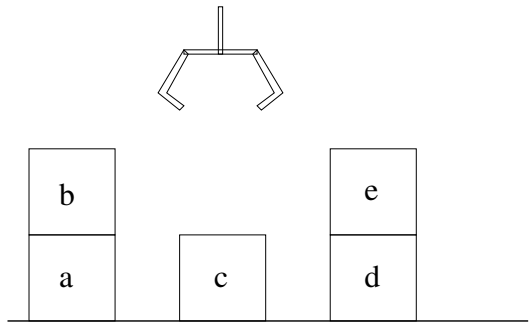
Se basan en la repetición del **ciclo "recoger información-pensar-actuar"**. Asumen como válida la hipótesis del sistema físico de símbolos, y tienen modelos del ambiente, muchas veces muy detallados, que tratan de llenar ("instanciar") con datos recogidos por los sensores. Como consecuencia:

- Hay que dotar explícitamente al agente de un **modelo simbólico** para el mundo (típicamente, un subconjunto de la lógica de predicados de primer orden).
- Hay que dar una **especificación simbólica** de las acciones disponibles para el agente (típicamente, en forma de listas PBA (precondición-borrado-adición)).
- Hay que programar en el agente **algoritmos de planificación**, que toman como entrada una descripción simbólica de un estado actual del mundo, y un objetivo, y generan como salida una secuencia de acciones que llevan al mundo desde el estado inicial hasta el estado objetivo.

Ejemplo de arq. deliberativa: STRIPS (I)

El mundo de bloques y STRIPS

Tomaremos como ejemplo un agente robótico actuando en el llamado "mundo de bloques". Se asume que los bloques están sobre una mesa y que un robot puede asirlos, moverlos y soltarlos.



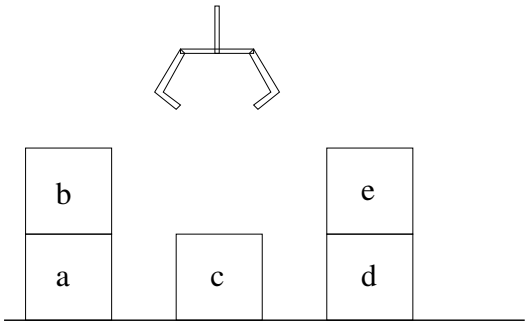
Los predicados que describirán el estado del mundo serán

- `on(U,V)`: el bloque `U` está sobre el bloque `V`.
- `clear(U)`: el bloque `U` no tiene nada sobre él.
- `gripping(U)`: la mano está asiendo el bloque `U`.
- `gripping()`: la mano no está asiendo nada.
- `ontable(W)`: el bloque `W` está sobre la mesa.

Las acciones atómicas serán (siendo `X,Y,Z,U,V,W`variables):

- `goto(X,Y,Z)` Lleva el brazo a las coordenadas `(X,Y,Z)`
- `pickup(W)` Recoge el bloque `W`. Lleva implícita un `goto` a las coordenadas del bloque
- `putdown(W)` Deja el bloque sobre la mesa.
- `stack(U,V)` Apila el bloque `U` sobre el `V`.
- `unstack(U,V)` Desapila el bloque `U` que estaba sobre el `V`.

Ejemplo de arq. deliberativa: STRIPS (II)



El estado de la figura vendría descrito por la conjunción de

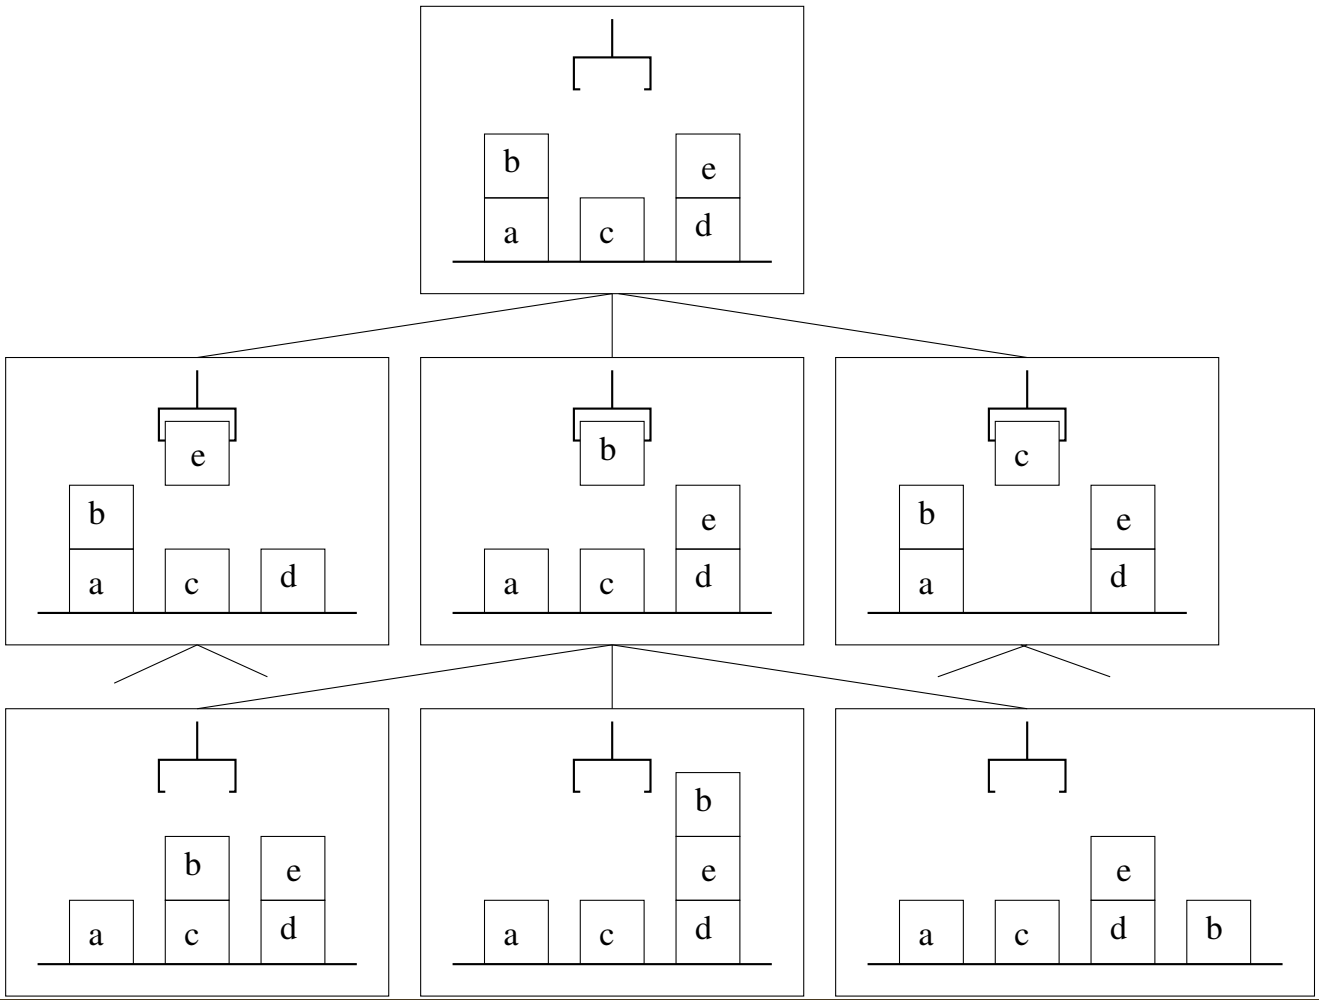
$$\left\{\begin{array}{lll} ontable(a). & on(b,a). & clear(b). \\ ontable(c). & on(e,d). & clear(c). \\ ontable(d). & gripping(). & clear(e). \end{array}\right.$$

Una forma compacta de representar los operadores es mediante listas (P,A,D) (precondition-add-delete):

pickup(X)	P: gripping() & clear(X) & ontable(X) A: gripping(X) D: ontable(X) & gripping()
putdown(X)	P: gripping(X) A: ontable(X) & clear(X) & gripping() D: gripping(X)
stack(X,Y)	P: clear(Y) & clear(X) & gripping(X) A: on(X,Y) & gripping() D: clear(Y) & gripping(X)
unstack(X,Y)	P: clear(X) & gripping() & on(X,Y) A: gripping(X) & clear(Y) D: gripping() & on(X,Y)

Ejemplo de arq. deliberativa: STRIPS (III)

En el estado de la figura se podrían aplicar los operadores *unstack*(e), *unstack*(b) o *pickup*(c). Un pequeño fragmento del espacio de estados puede verse aquí:



Clas. B: Arquit. reactivas (comportamentales)

En ellas no se realizan modelos del ambiente (o son modelos mínimos, poco detallados) y las interacciones se resuelven mediante la actuación concurrente de módulos comportamentales.
Un **módulo comportamental** es una pieza de hardware+software+entorno que conecta directamente percepción y acción (básicamente, en modo estímulo/respuesta). Los módulos comportamentales se comunican entre sí simplemente con señales de activación/inhibición, o incluso no lo hacen, dejando que la comunicación se realice a través del entorno.
Las principales propiedades de las arquitecturas comportamentales son:

- Inteligencia emergente
- Fusión a bajo nivel de percepción y acción
- Paralelismo
- Rechazo de las representaciones simbólicas
- Uso activo del mundo (entorno)
- Minimalismo

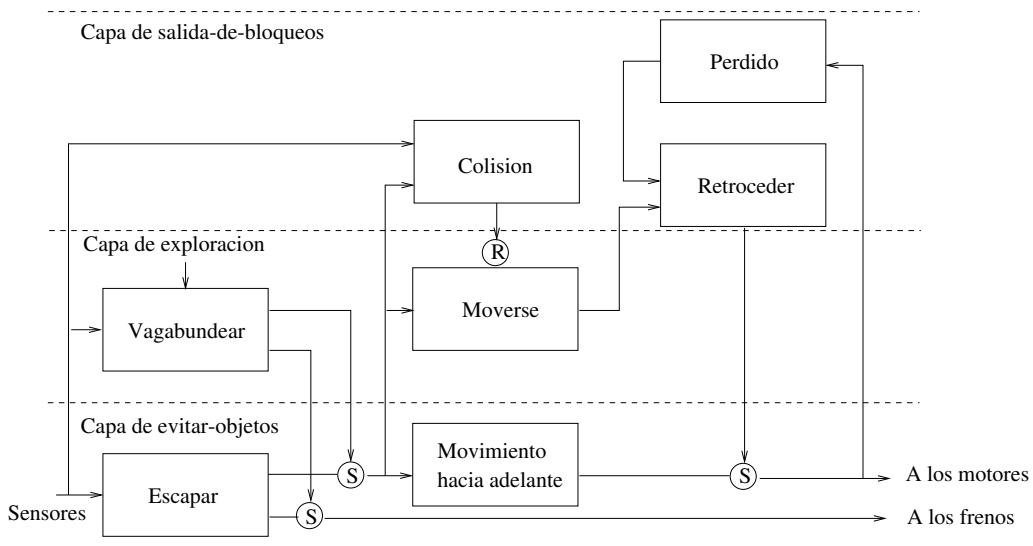
Ejemplo de arq. reactiva: arq. de subsumción

Arquitectura de subsumción de Brooks

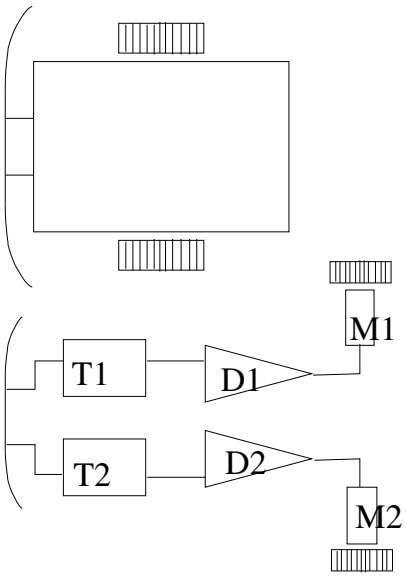
A las propiedades ya citadas para las ACs Brooks añade:

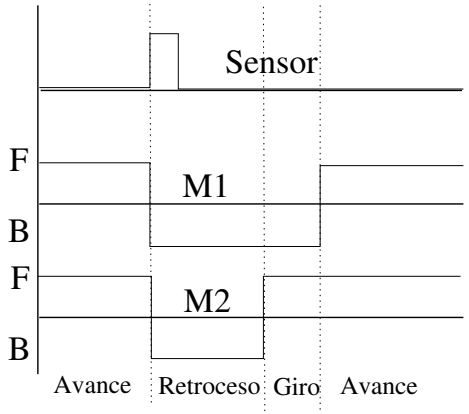
- Inteligencia como proyección del observador
- Robustez ante ruido o fallo de los sensores
- Construcción incremental de sistemas autónomos
- Rechazo de las representaciones, la calibración, los algoritmos complejos y las comunicaciones de banda ancha

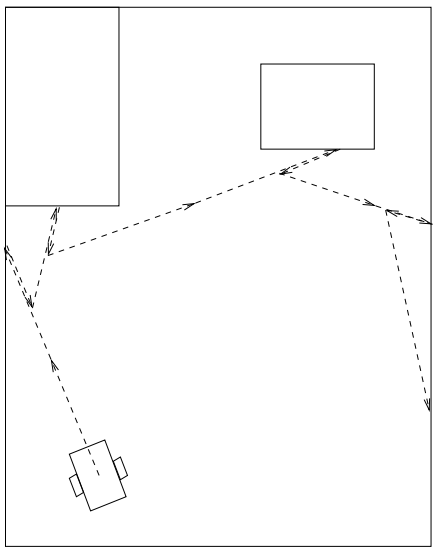
Ejemplo simple con tres capas implementado en un coche de juguete:

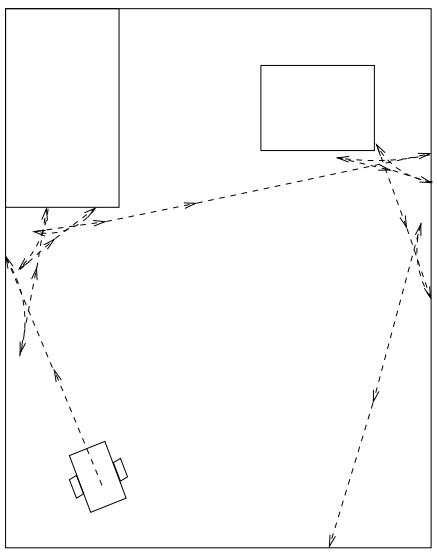


Ejemplo de inteligencia proyectada: TutBot



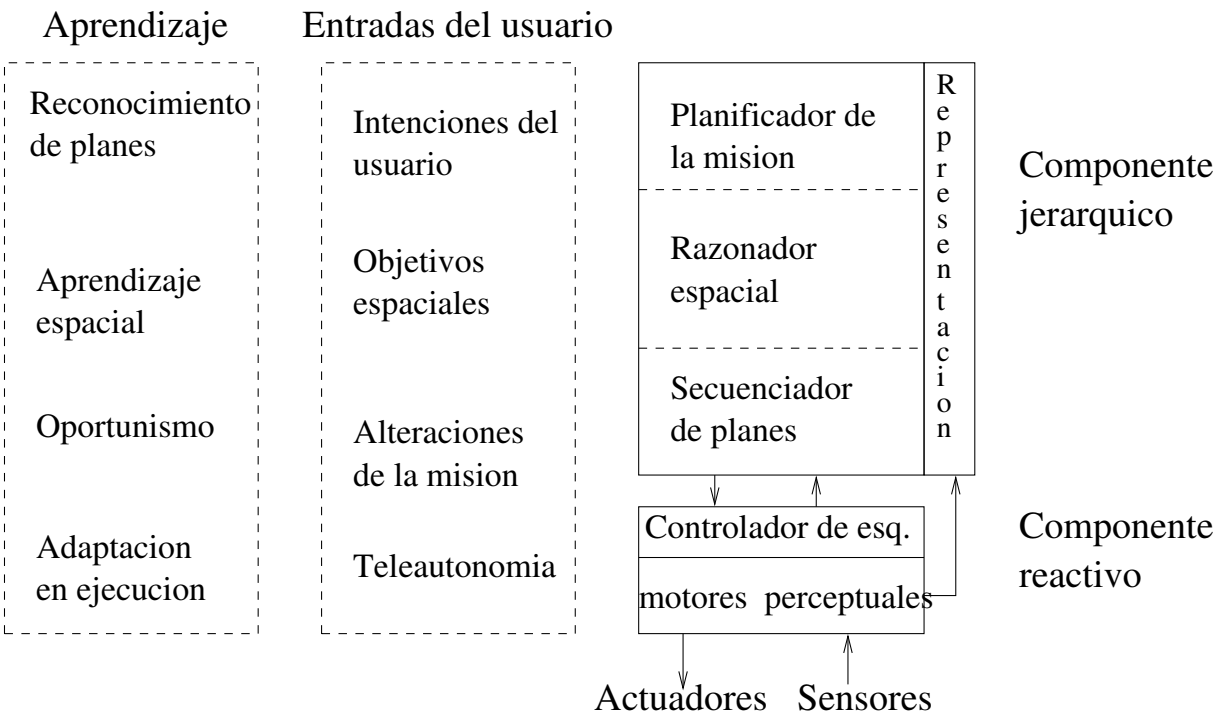






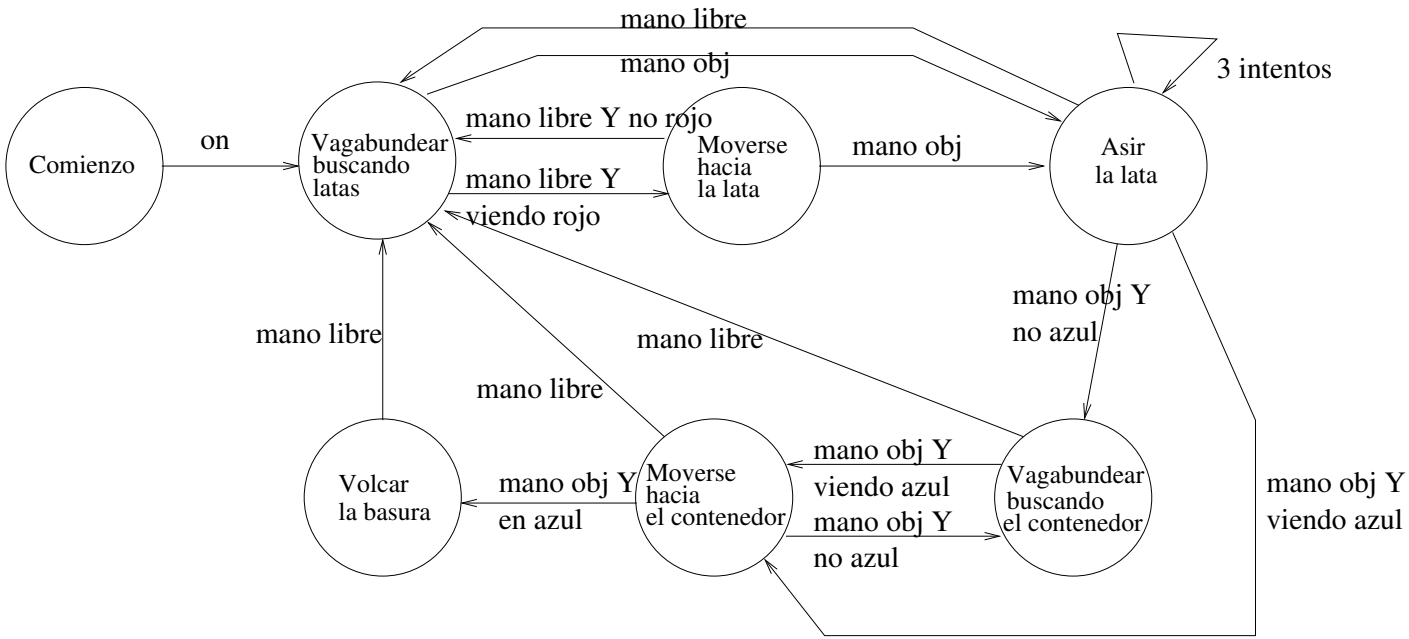
Clas. B: Arquitecturas híbridas

Son combinaciones de las dos anteriores, donde el agente tiene una parte reactiva y una parte deliberativa. En general, se emplea la parte reactiva para las acciones de bajo nivel (evitar obstáculos, moverse en dirección a un estímulo) y la deliberativa para planificar a medio/largo plazo (control de misión).
Un buen ejemplo es la arquitectura AURA (Arkin):



Ejemplo de arquitectura híbrida: AURA

El secuenciador de planes es un autómata finito. Un ejemplo para recoger latas de refresco:



Hay sensores de infrarrojos entre los dedos para ver si la mano está libre o asiendo un objeto. Hay sensores visuales para determinar si hay una mancha de cierto color, y qué tamaño tiene (para distinguir entre 'viendo ...' y 'en ...'. 'no color' significa 'no se está viendo mancha de ese color'.

Arquitec. multiagente (AMAs): definición

Son arquitecturas que intentan coordinar múltiples agentes para actuar sobre un único entorno (como las sociedades de agentes, o la IA distribuída). Presentan serias dificultades, entre ellas:

- Los agentes pueden interferir entre ellos de modo no intencionado
- Es difícil reconocer cuándo uno o varios agentes son improductivos.
- En un problema particular no es obvio cuál es el grado correcto de individualidad y autonomía para cada agente.

AMAs: aspectos a considerar

Los aspectos relevantes que hay que tener en cuenta son:

- Equipos homogéneos vs. heterogéneos: ¿son o no todos los agentes iguales? Si no, ¿hay jerarquía?.
- Control centralizado vs. distribuído: ¿hay una planificación central única? Si es así, ¿la genera un único agente?. Si no, ¿pueden exhibirse comportamientos complejos?.
- Cooperación activa vs. no activa: ¿tienen en cuenta los agentes las acciones de los otros o no?. En caso afirmativo, ¿las conocen de antemano?.
- Comunicación entre agentes: Si hay comunicación explícita, es necesario definir formatos para el intercambio de mensajes (ACL: agent communication languages). Ejemplos son KQML (knowledge query and manipulation language), que define 34 verbos comunicativos entre agentes (ej. Ask-if ¿es cierto que...?) o FIPA (Foundation for Intelligent Physical Agents).

Ejemplo de AMA: Arquitecturas de pizarra

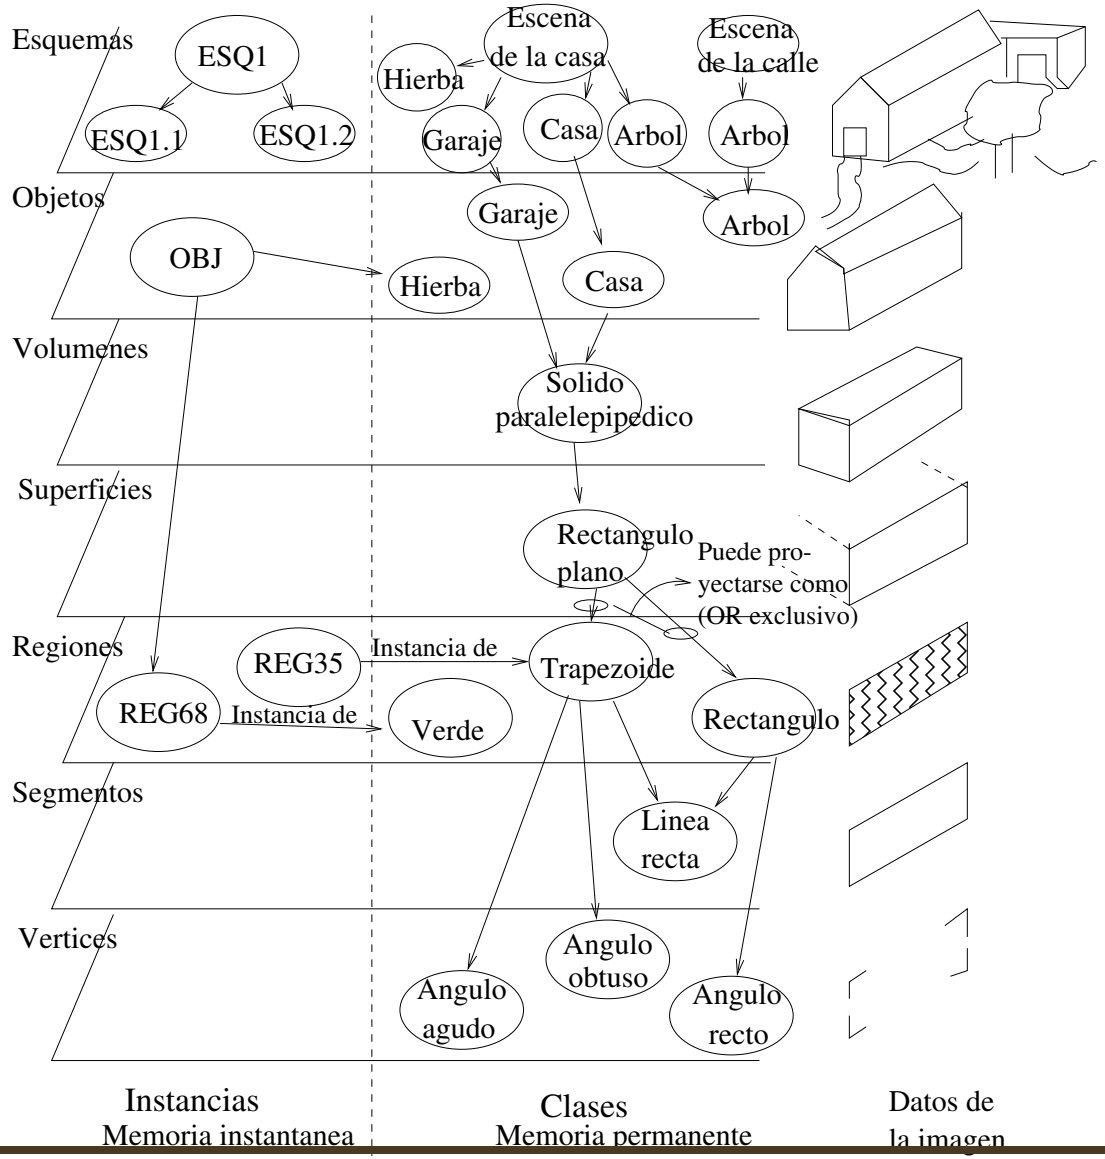
Tratan de emular un grupo de expertos que cooperan para obtener una solución a un problema. Sus características son:

- Existe una base de datos estructurada y global, llamada pizarra, con dos mitades: la mitad izquierda, en la que se anota el modelo del problema, y la mitad derecha con su estado actual de solución (inicialmente, vacía). Perpendicularmente, hay varios niveles, que representan soluciones con grados cada vez mayores de abstracción.
- Existe un conjunto de procesos (programas concurrentes) llamados fuentes de conocimiento (KS's) que, mirando (sólo lectura) la parte de modelo de la pizarra, y viendo el estado actual de la solución, generan una solución a un problema parcial, y la apuntan en la parte derecha. Un KS puede activarse si se dan ciertas condiciones relacionadas con el estado actual de la pizarra.
- Existe un mecanismo de control (proceso de reparto) que elige de entre todas las KS's que pueden activarse en cada momento, la que lo hará, sólo una cada vez. Esta elección puede depender de la fiabilidad de la fuente de conocimiento, de la credibilidad de la información de disparo, del valor esperado de la acción, etc.

Así pues, una arquitectura de pizarra es una AMA con equipo heterogéneo, control centralizado y cooperación activa, aunque sin comunicación explícita (ésta se hace a través de la propia pizarra).

Ejemplo de arq. de pizarra: VISIONS

VISIONS: Visual Integration by Semantic Interpretation of Natural Scenes



Definición de vida artificial (AL)

La vida artificial es la parte de la IA que trata de reproducir el fenómeno de la inteligencia por medio de la creación de múltiples agentes situados en un entorno que, a semejanza de la vida natural, se originen (nazcan), cambien (crezcan), generen otros agentes (se reproduzcan) y desaparezcan (mueran).
Es necesario dar reglas de creación, cambio, generación y desaparición de agentes, así como reglas básicas de interacción de los agentes entre sí y con el entorno, e introducir un mecanismo de cambios (mutaciones) para garantizar el cambio global de la morfología y el comportamiento de la comunidad completa.

Posibilidades de implementación de AL

Algoritmos genéticos (GAs)

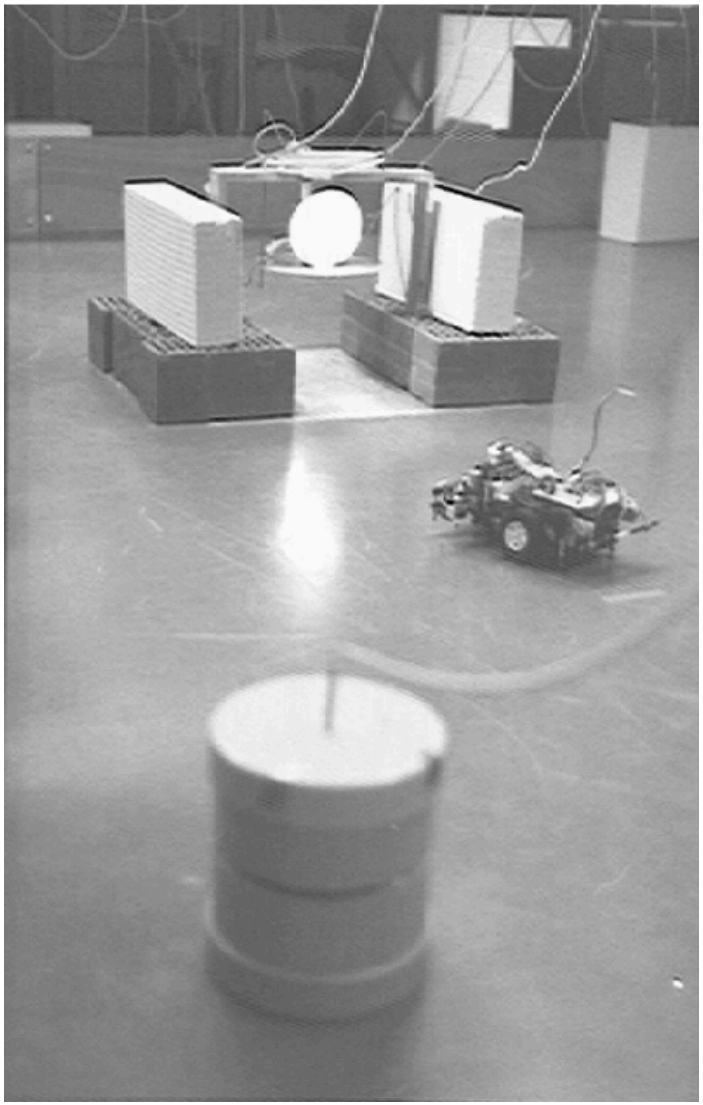
Un GA es un método de optimización para encontrar la solución óptima a un problema con enorme cantidad de ellas. Se basa en:

1. Codificar cada solución como una cadena de bits (un individuo, i) y crear aleatoriamente un grupo grande de ellas, la población.
2. Evaluar la función de rendimiento del problema para cada i, sea $R(i)$.
3. Asignar a cada individuo una probabilidad de reproducción $p_r(i)$ proporcional a $R(i)$.
4. Elegir a varios individuos con probabilidad $p_r(i)$, y cruzarlos.
5. Sustituir en la población los individuos con menor valor de $R(i)$ por los recién generados.
6. Introducir cambios aleatorios en algún bit de algún/algunos elementos de la población (mutaciones).
7. Ir al paso 2 (siguiente generación).

El algoritmo acaba cuando se ha encontrado un individuo con valor suficientemente alto de $R(i)$.

Ejemplo de comportamiento evolutivo

Desarrollo de lenguaje: las comunidades de robots de Steels



Un grupo de robots móviles tienen sensores que les permiten detectar la dirección de la luz (nido) y detectar unos postes. El nido con la luz sirve para recargarse. Sólo puede haber un robot recargándose cada vez. La luz sólo alumbra si los postes no le quitan demasiada energía, y para evitar que eso ocurra los robots deben golpearlos habitualmente. Las distancias son tales que un sólo robot no puede sobrevivir: si acapara la recarga, los demás mueren, no golpean los postes, y con ello, él termina muriendo también, pero si siempre golpea y no se recarga nunca, también muere.

Experimentos:

- Sin comunicación explícita: aparición de temperamentos.
- Con comunicación explícita: juegos linguísticos, extensión del léxico y (aún no) de la sintáxis.
- Idea del "yo": otros se refieren a mí.